รหัสวิชา 2-233-225
ชื่อวิชา วิทยาศาสตร์ข้อมูลเบื้องต้น
(Introduction to Data Science)
สัปดาห์ที่ 2

CS

เนื้อหาของรายวิชา

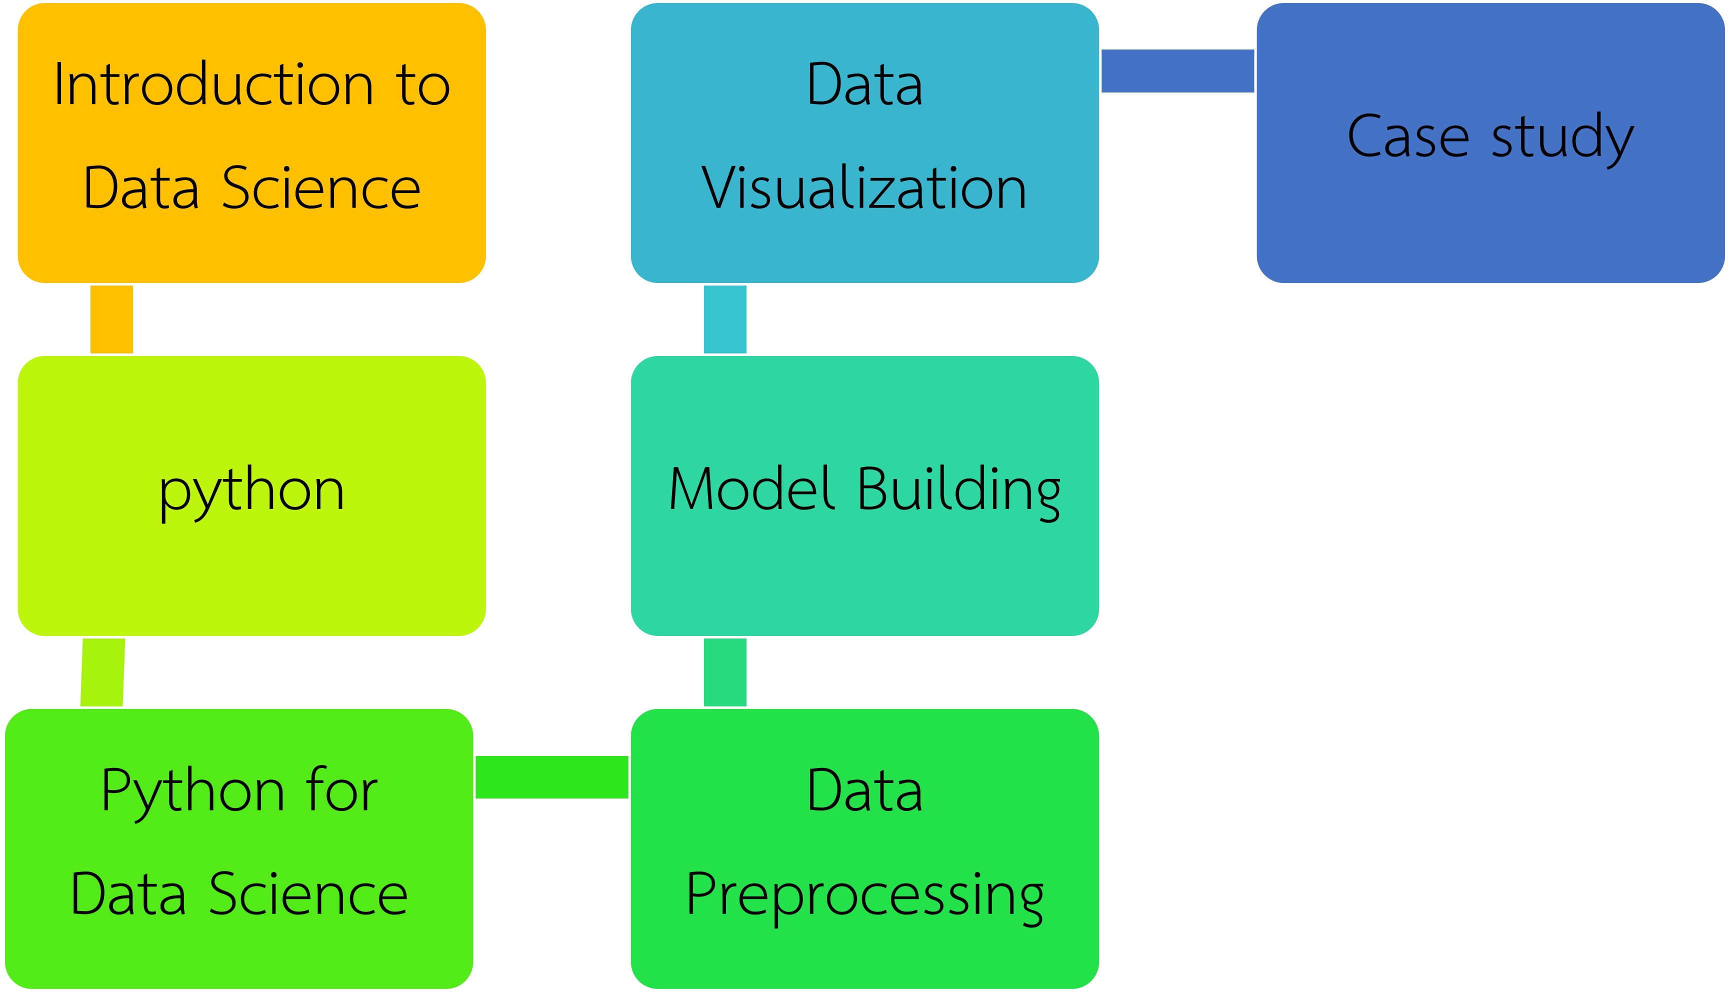

CS

ภาพรวมของ Data Science

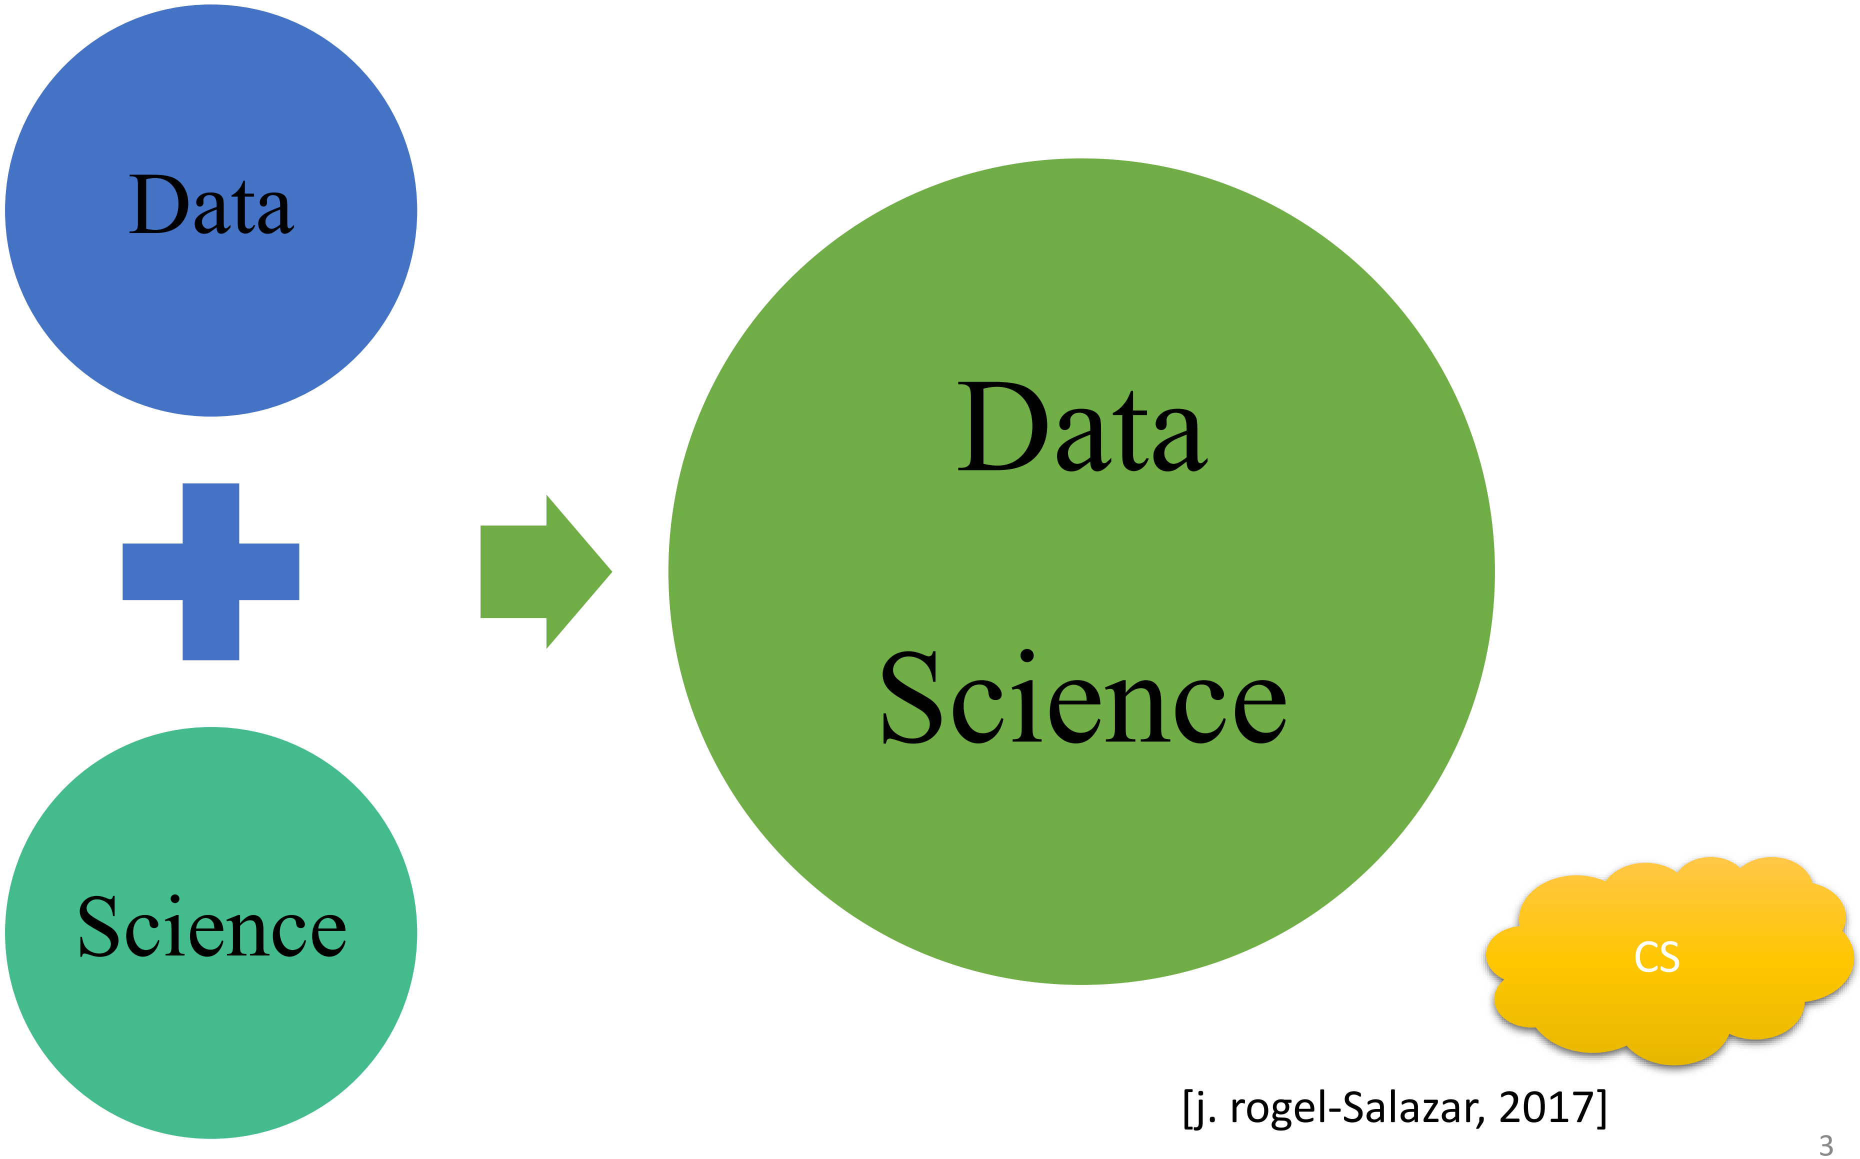

[j. rogel-Salazar, 2017]

Data

CS

Big Data

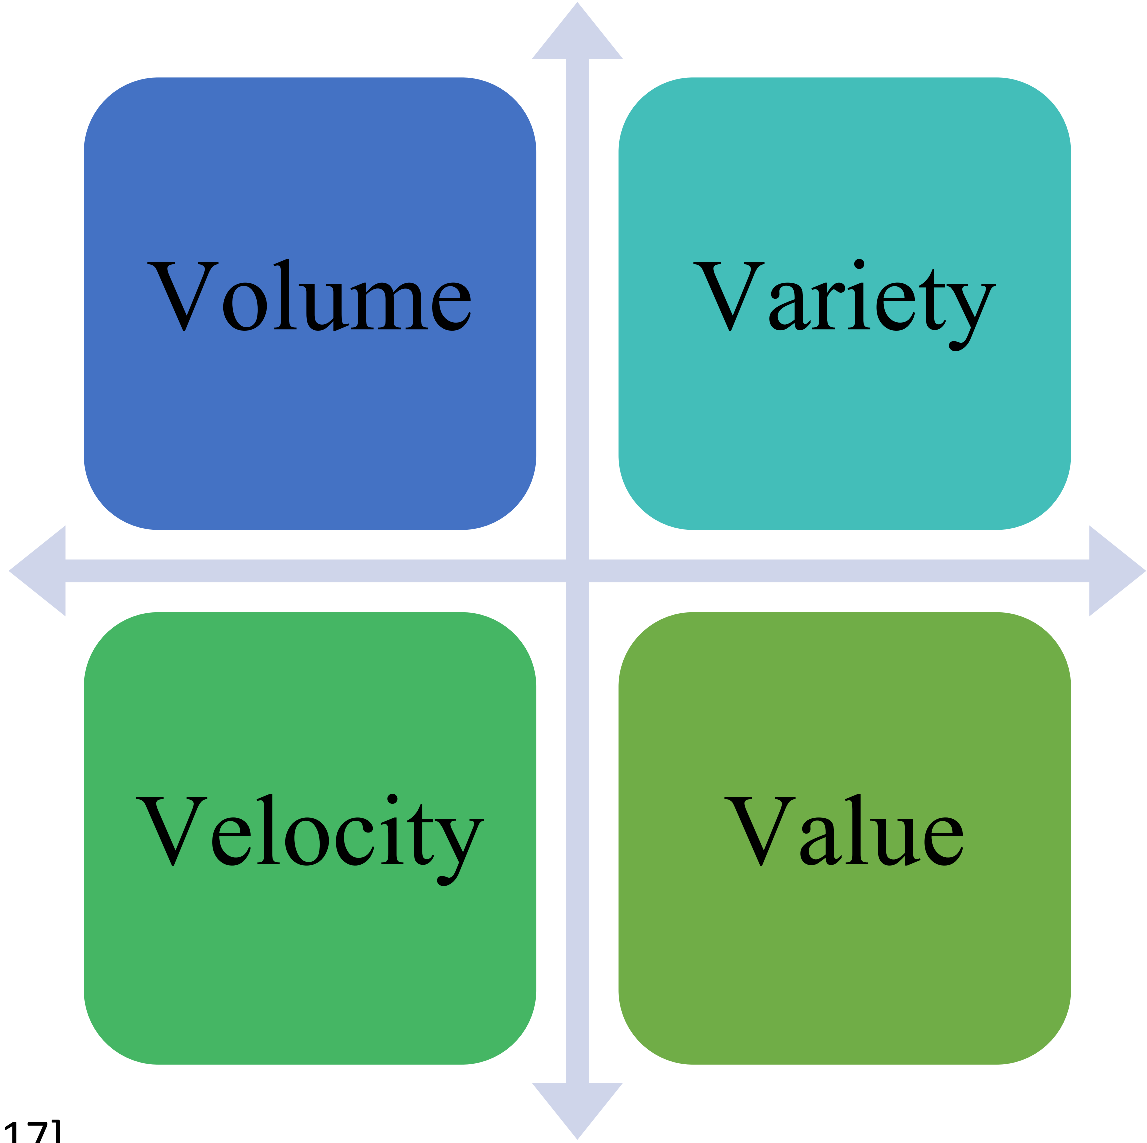

[j. rogel-Salazar, 2017]

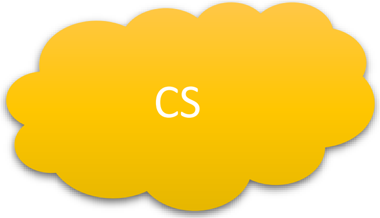

Data Science คืออะไร.....

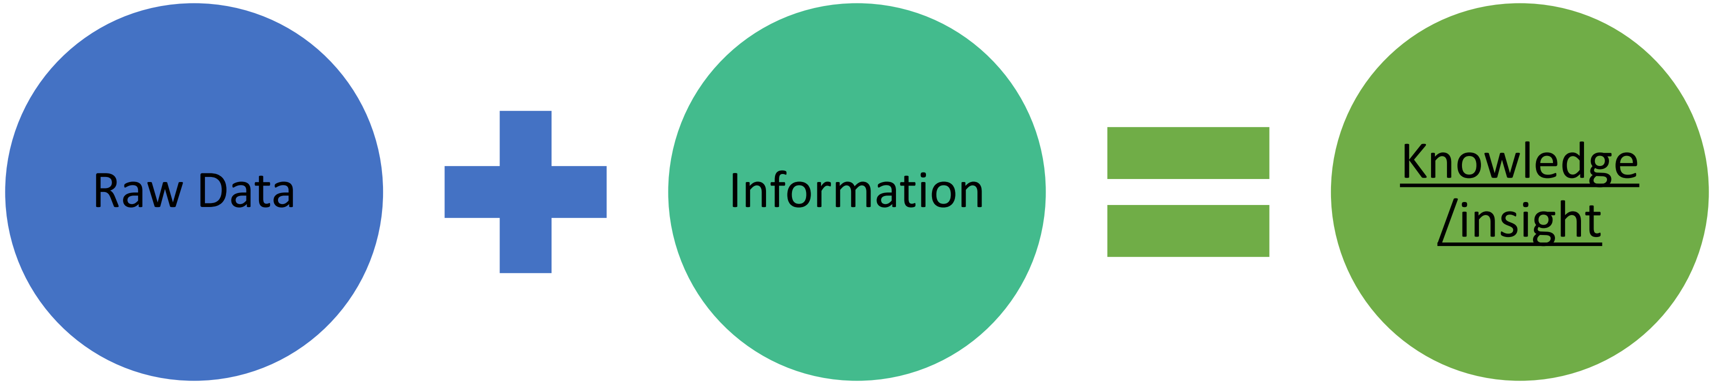

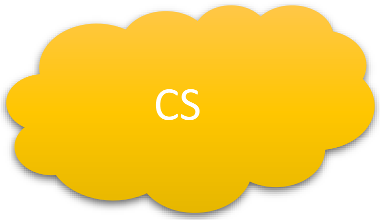

[j. rogel-Salazar, 2017]

วัตถุประสงค์ของบทนี้

- เพื่อเข้าใจขั้นตอนของการทำ Data Science
- เพื่อเข้าใจขั้นตอนการติดตั้ง Anaconda
- เพื่อเข้าใจการใช้งาน Jupiter notebook
- เพื่อเข้าใจภาษา Python เบื้องต้น

CS

ขั้นตอนการทำ Data Science

Data Science Pipeline

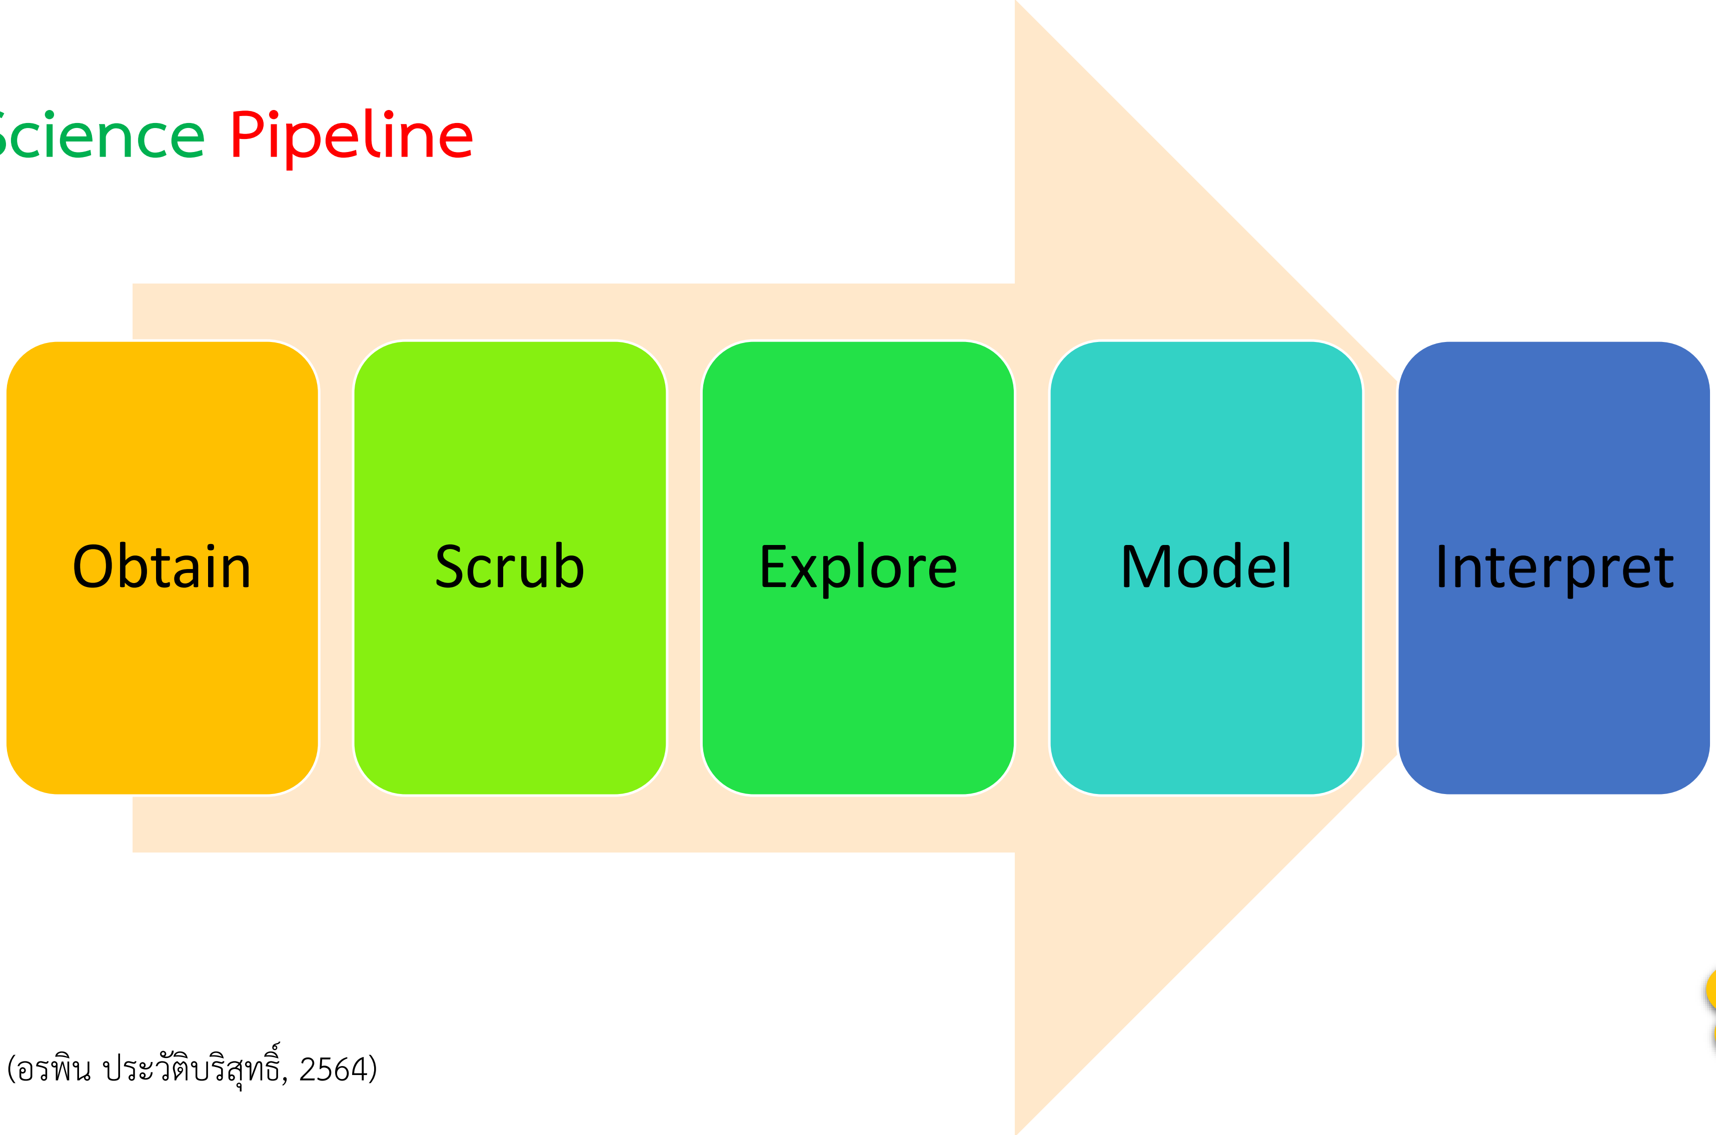

CS

(อรพิน ประวัติบริสุทธิ์, 2564)

Obtain

- Business/Problem definition

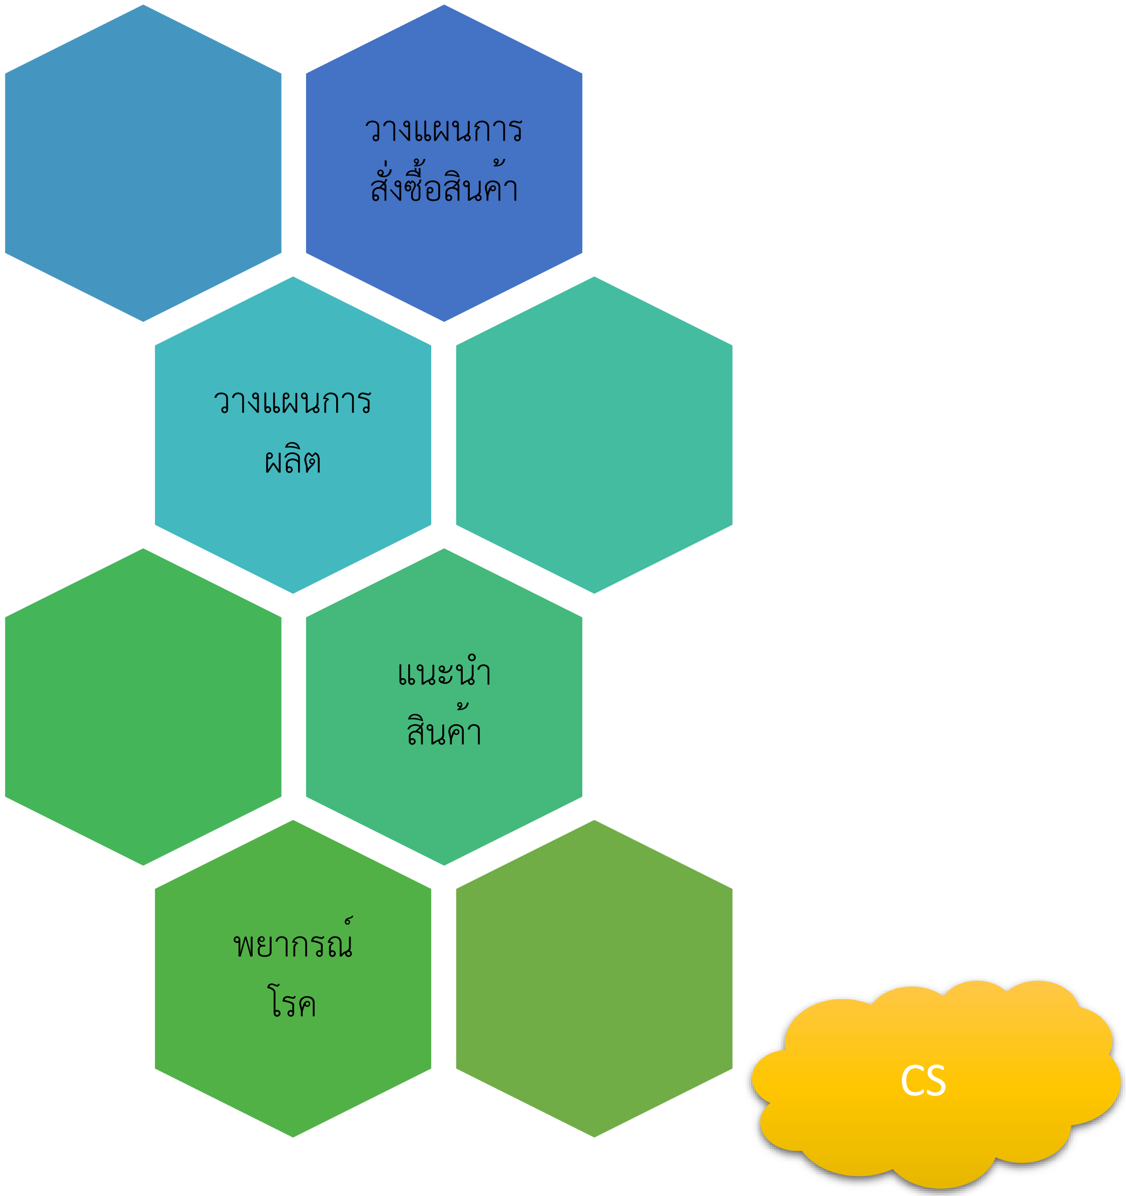

Obtain

- ➢Data Acquisition

- แบบสอบถาม
- เข้าชมเว็บ
- ข้อมูลการสั่งซื้อสินค้า
- ข้อมูลจากฐานข้อมูลขององค์กร
- ข้อมูลจาก sensor
- ข้อมูลจาก social media

ชนิดของข้อมูล

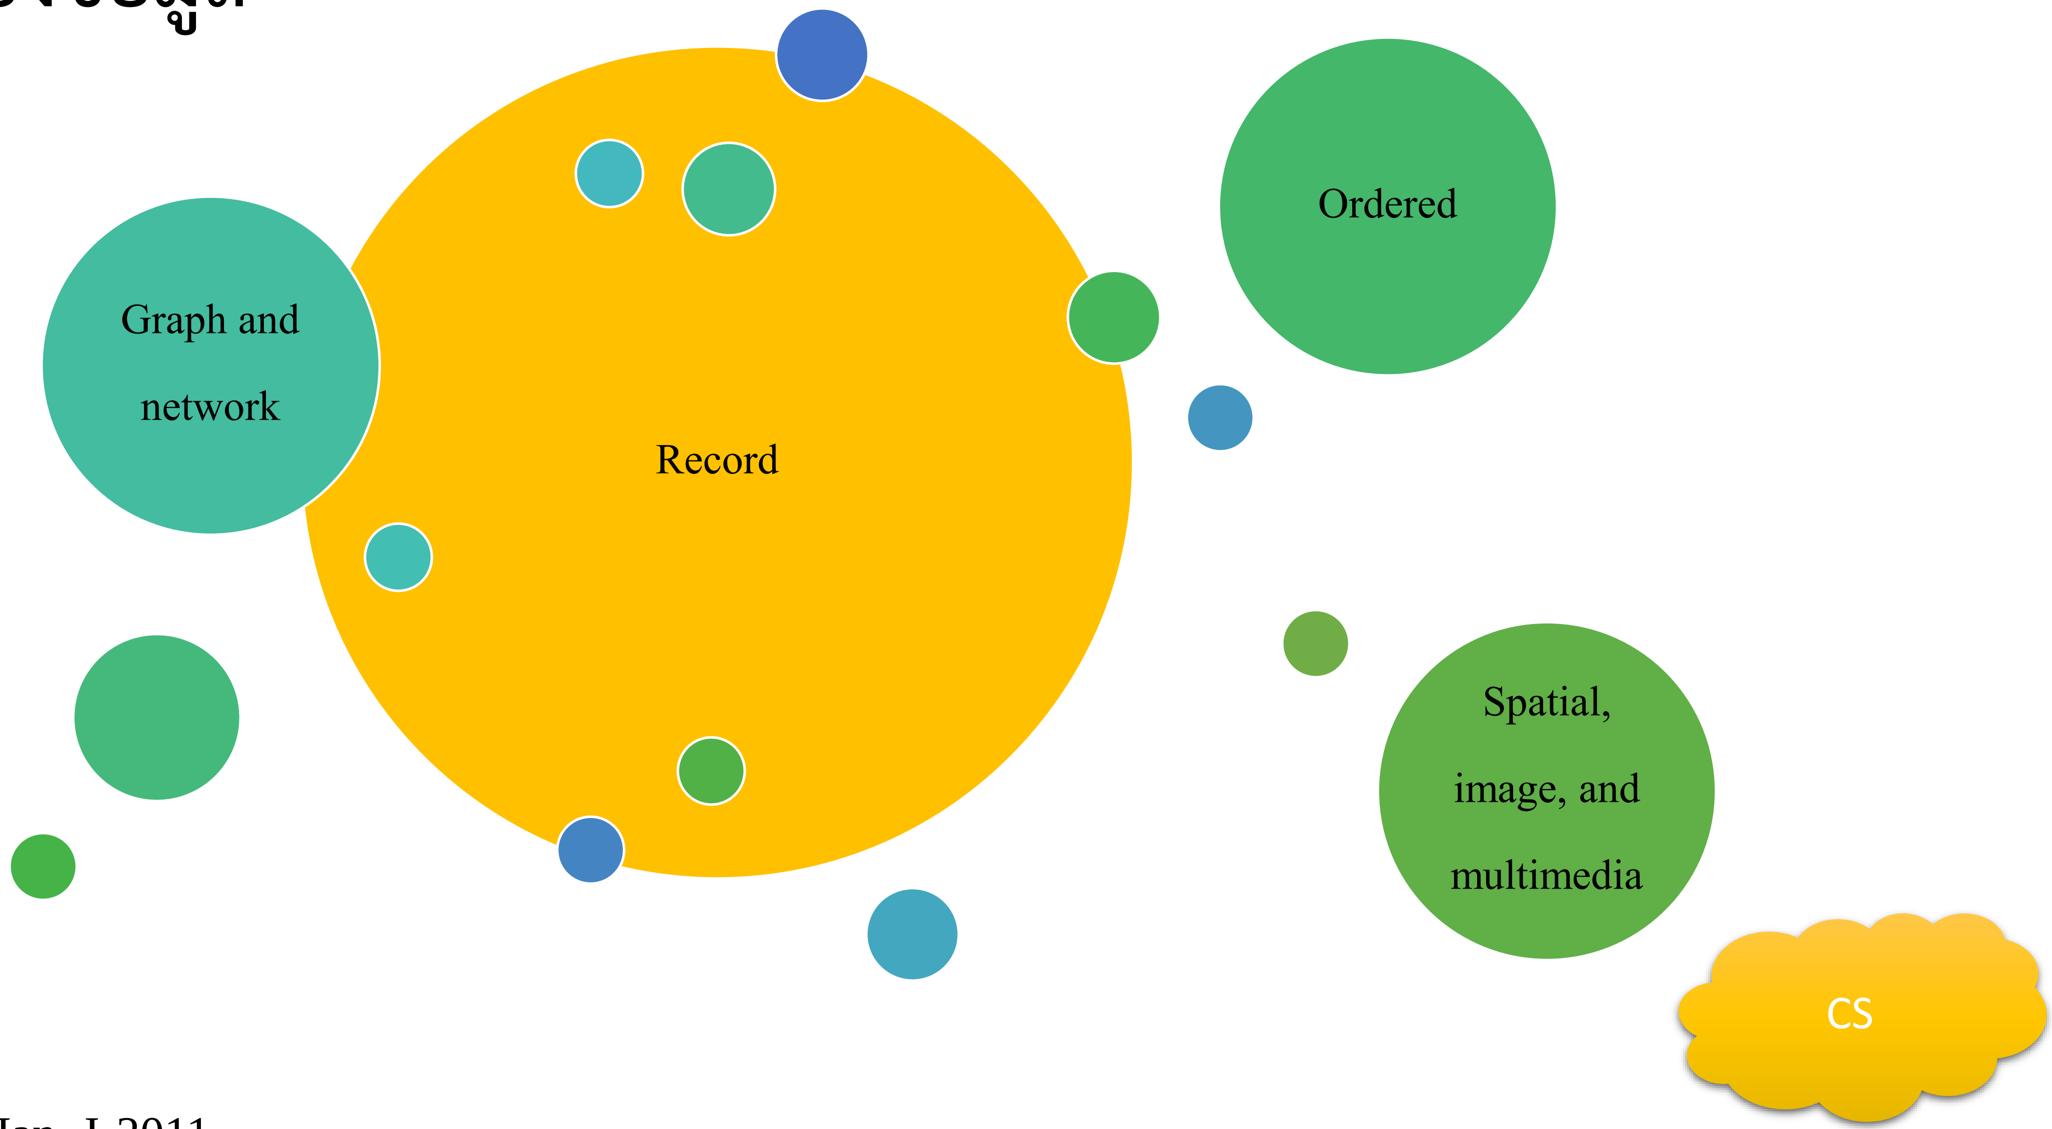

Han, J. 2011

Data Objects

samples , examples, instances, data points, objects, tuples

Attributes, dimensions, features, variables

	A	B	C	D	E	F
1	Region	Product Group	Quantity (Kg)	Revenue	Date	SalesRep
2	East	Pet Food	3003	30,938	31/12/2557	s008
3	East	Cooked food	1500	79,284	14/04/2557	s002
4	East	Cooked food	3000	66,570	4/07/2557	s007
5	South	Sausage	5000	38,878	20/09/2557	s006
6	East	Pet Food	3276	61,212	27/12/2557	s008
7	West	Fresh food	1500	84,358	26/12/2557	s008
8	South	Cooked food	1500	79,258	2/06/2557	s007
9	East	Sausage	3000	97,132	30/01/2557	s003
10	South	Sausage	3000	65,119	25/07/2557	s004
11	Central	Cooked food	3000	83,079	8/07/2557	s003

Han, J. 2011

CS

Scrub

- Data preparation
  - ✓ Data cleaning

แตกข้อมูล → เปลี่ยนรูปแบบข้อมูล → แยกคำ → จัดการค่าที่ขาดหายไป

CS

Explore


การวัดค่ากลาง
การวัดความสมมาตรและความโน้มเอียงของข้อมูล
การวัดการกระจายตัวของข้อมูล
กราฟ

CS

สถิติพื้นฐาน

✓ การวัดค่ากลาง (Measuring the Central Tendency)

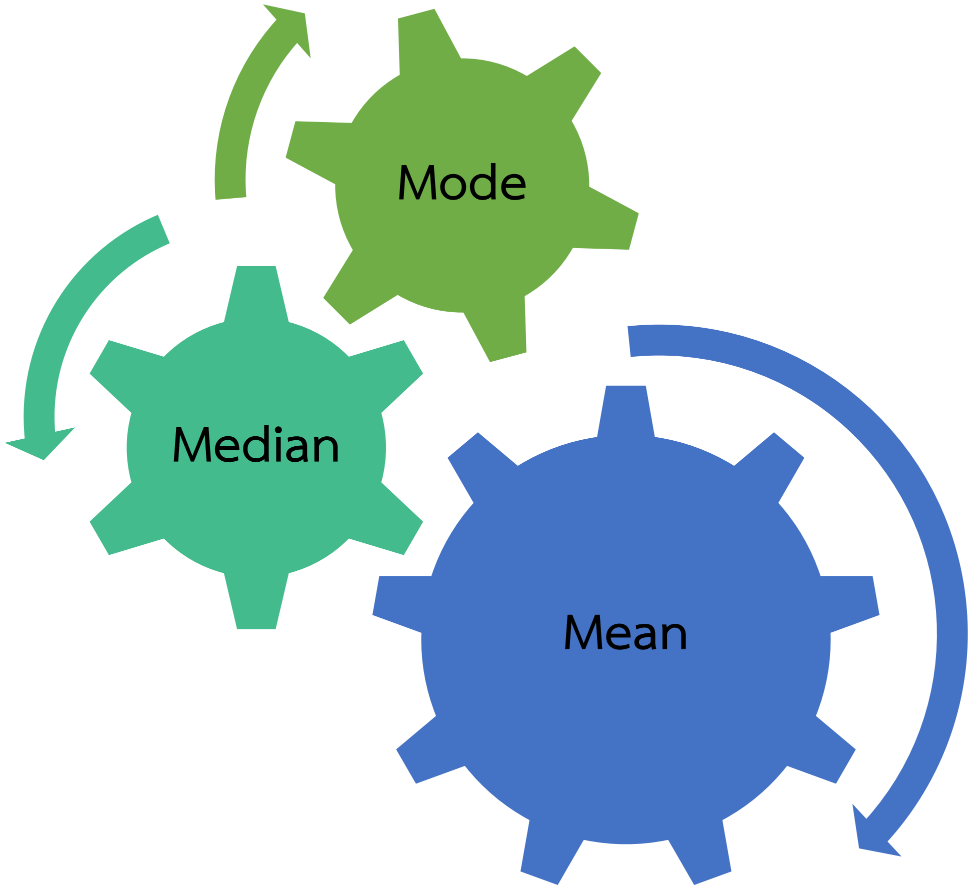

CS

Han, J. 2011

การวัดความสมมาตรและความโน้มเอียงของข้อมูล (Symmetric และ Skewed Data)

✓Symmetric

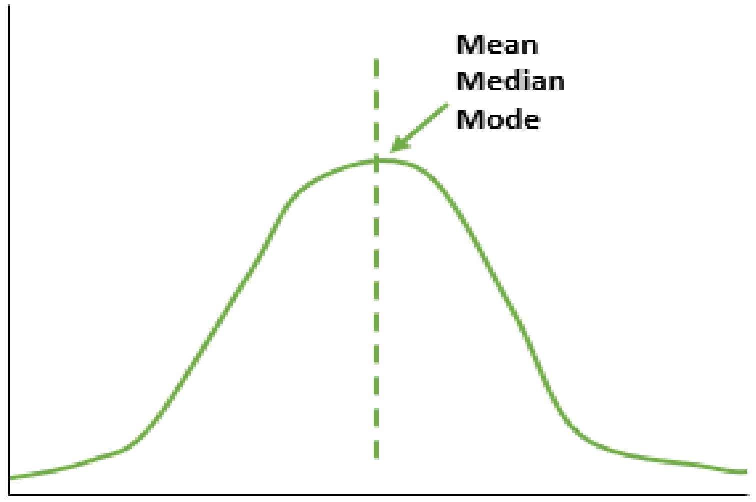

✓Left skewed

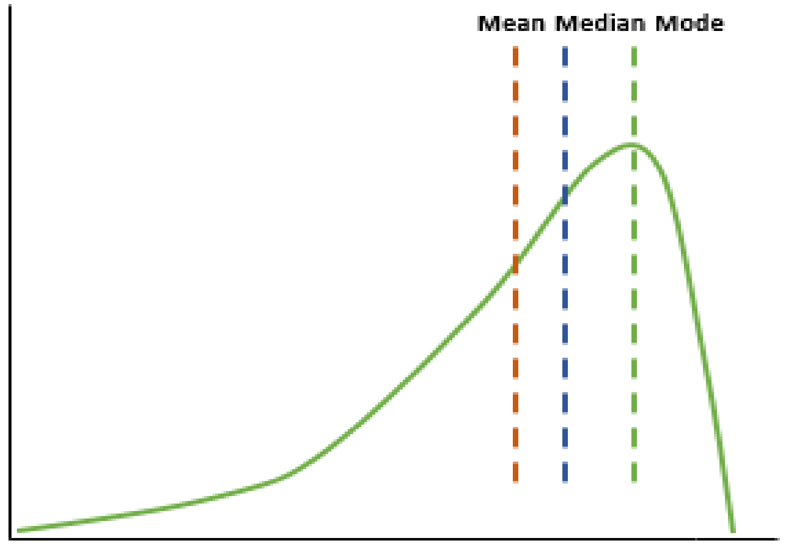

Han, J. 2011

CS

การวัดความสมมาตรและความโน้มเอียงของข้อมูล (Symmetric และ Skewed Data)

✓ Symmetric

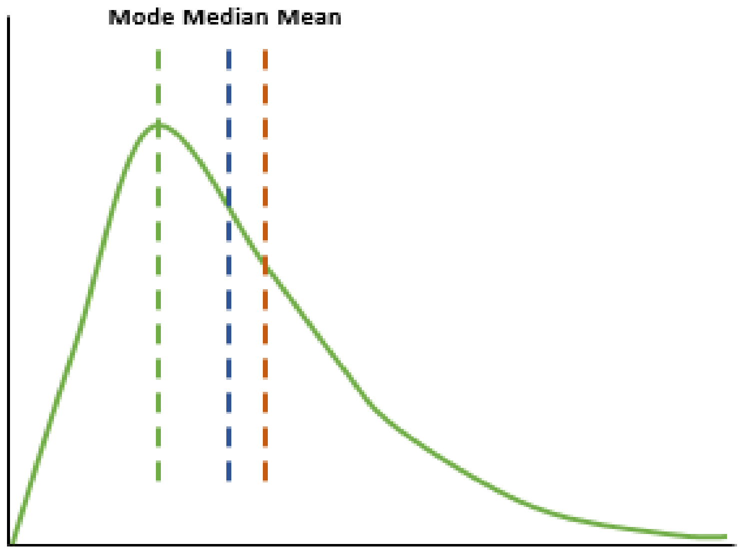

Han, J. 2011

CS

การวัดการกระจายตัวของข้อมูล

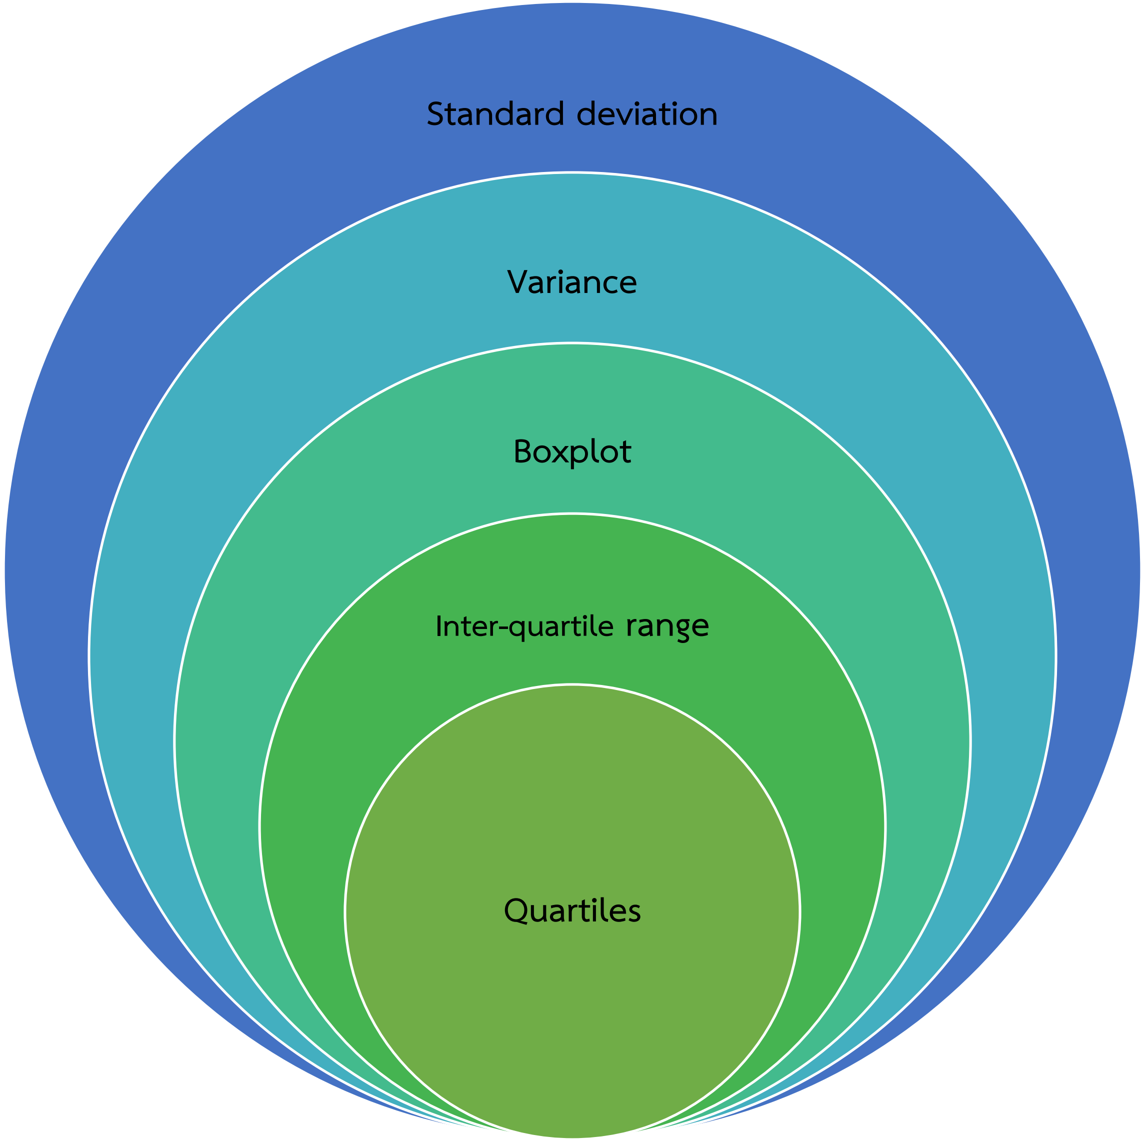

CS

Han, J. 2011

กราฟ

Histogram

- Histogram เป็นกราฟสำหรับใช้ในการนำเสนอความถี่ของข้อมูลโดยใช้กราฟแท่ง (bar graph) ที่เรียงติดกันไม่มีช่องว่างเพื่อดูการกระจายของข้อมูล

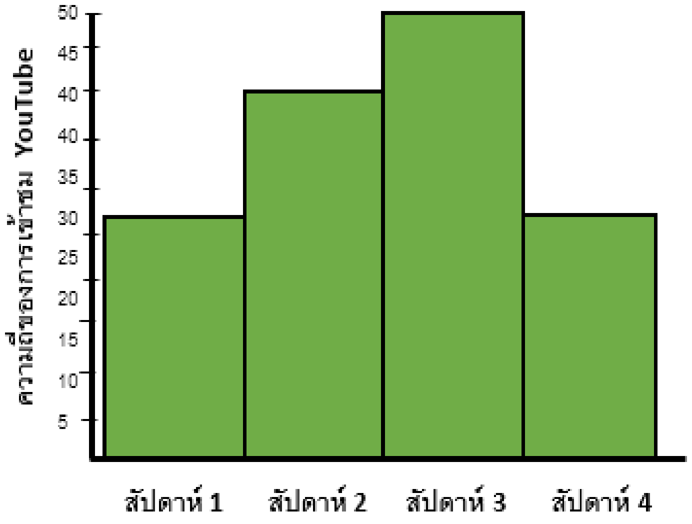

Han, J. 2011

Scatter plot

- Scatter plot เป็นกราฟสำหรับใช้ในการนำเสนอความสัมพันธ์ของ 2 ตัวแปร (Bivariated data) เพื่อดูความสัมพันธ์ระหว่างตัวแปร X และ Y ว่ามีความสัมพันธ์แปรผันกันหรือแปรผกผันกันเพื่อนำมาตรวจจับข้อผิดพลาด (outliers)

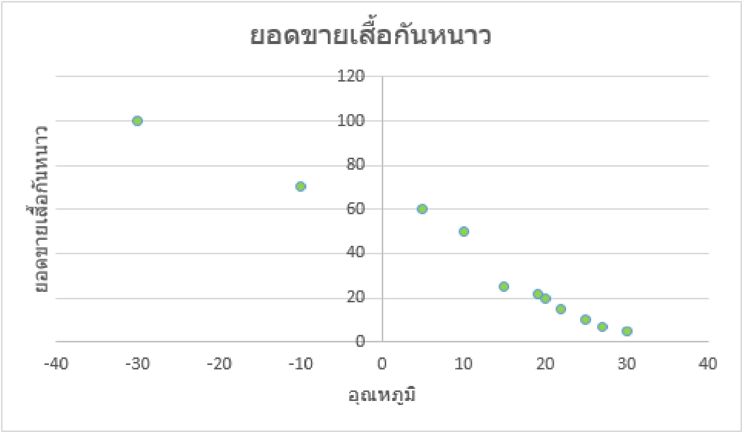

Model

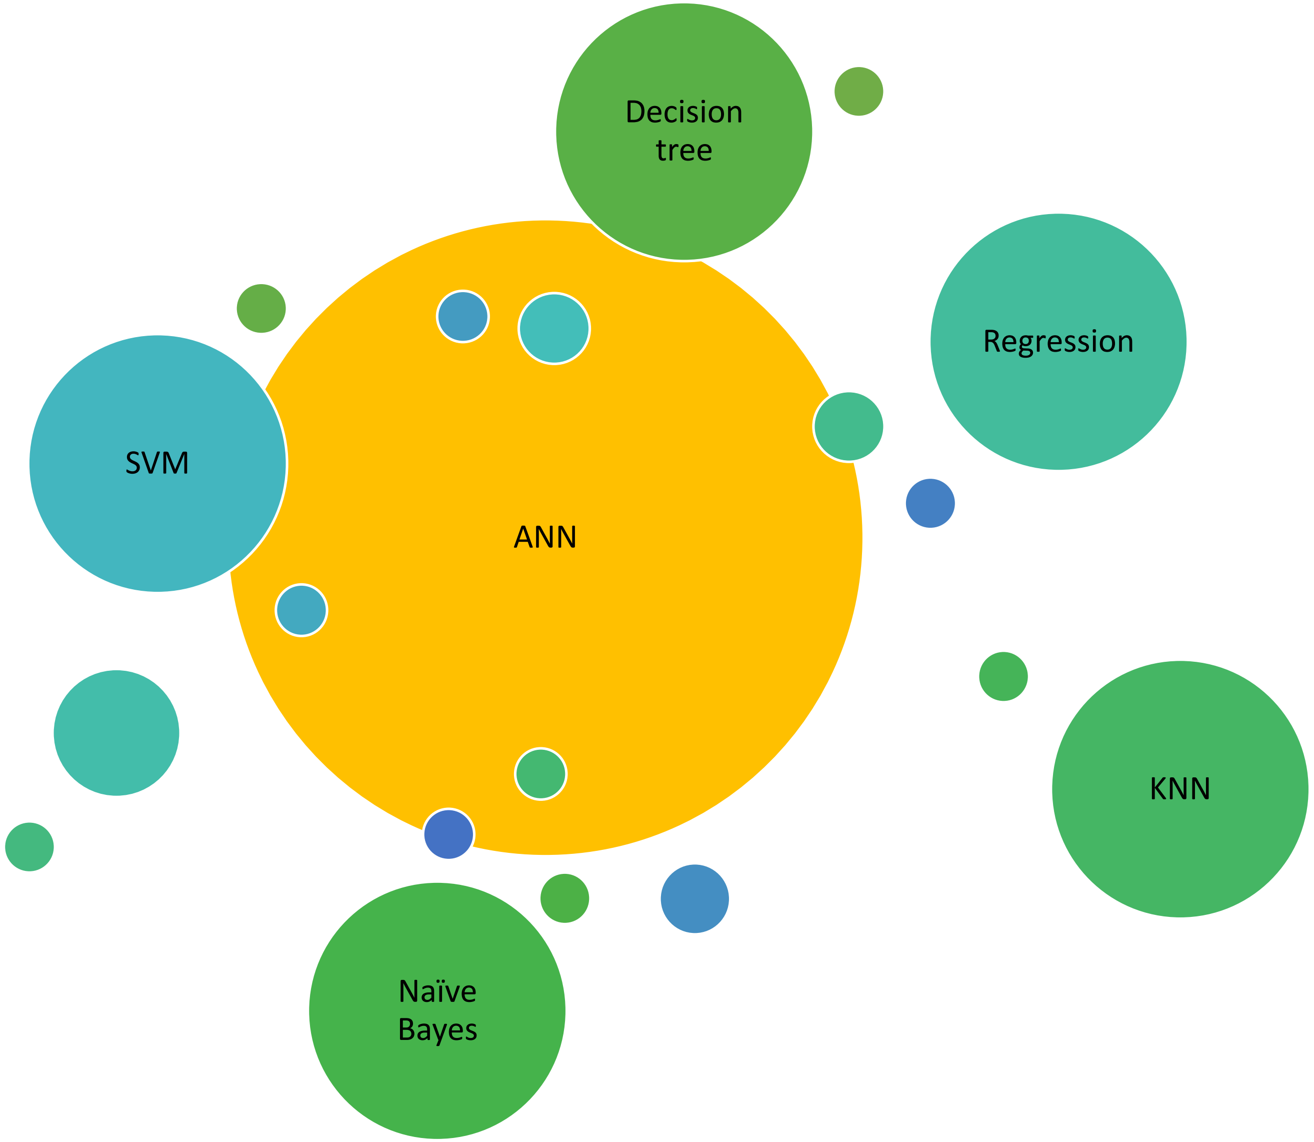

Interpret

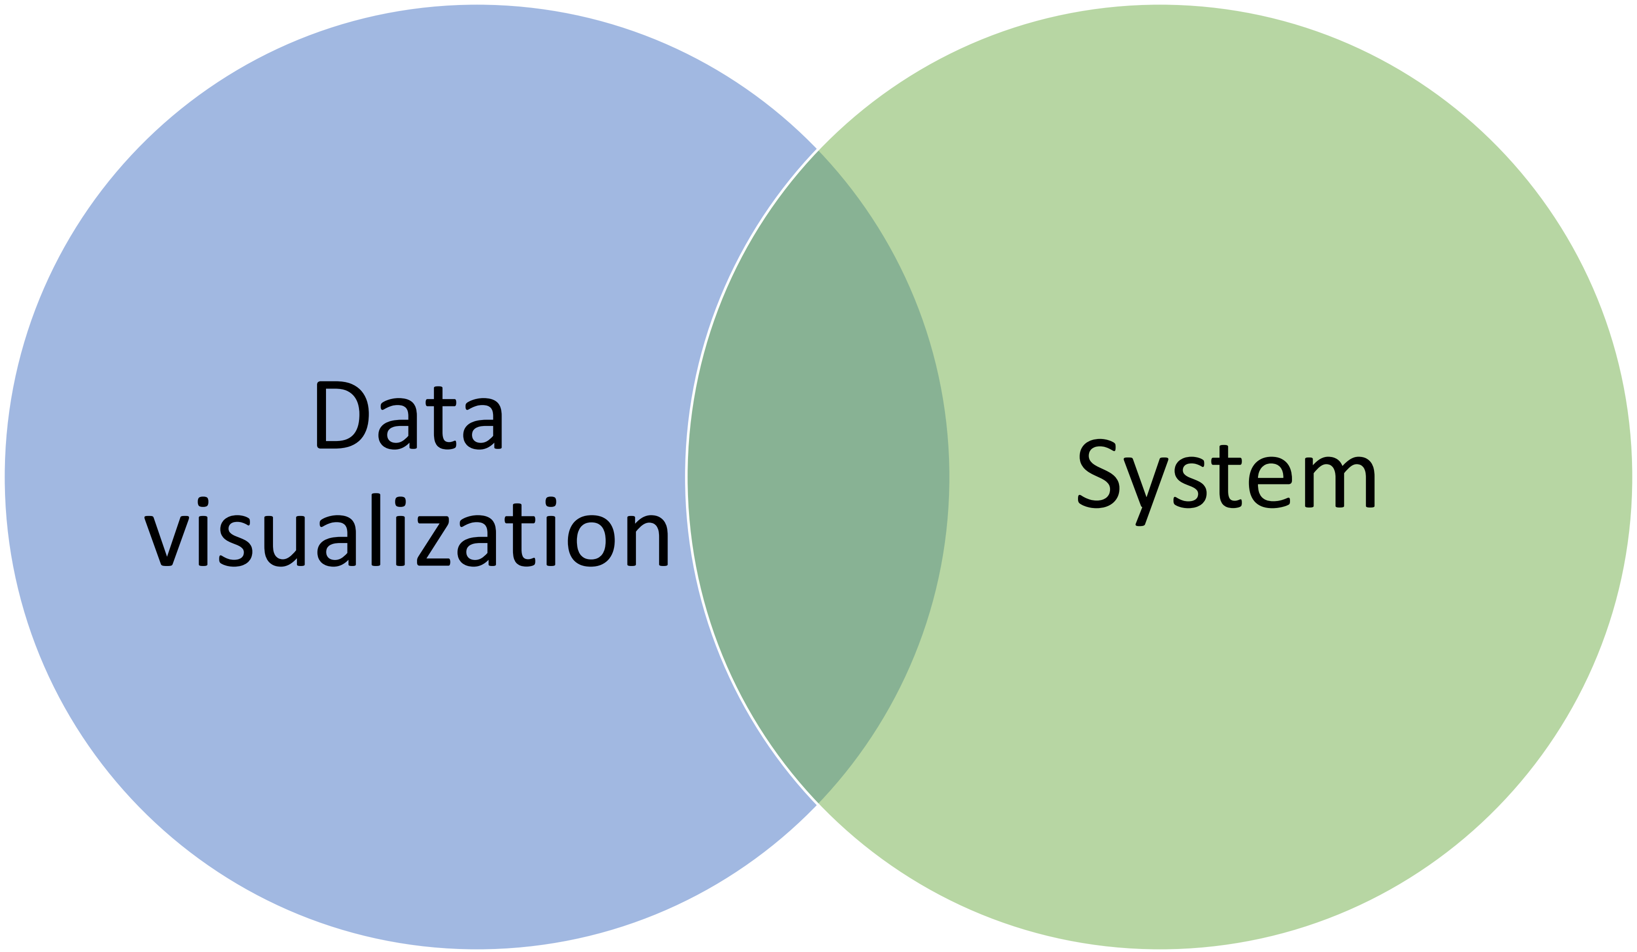

Python

Web development

Networking

Science computing

Data analytics

CS

[Jesús Rogel-Salazar. DATA, 2017]

Python

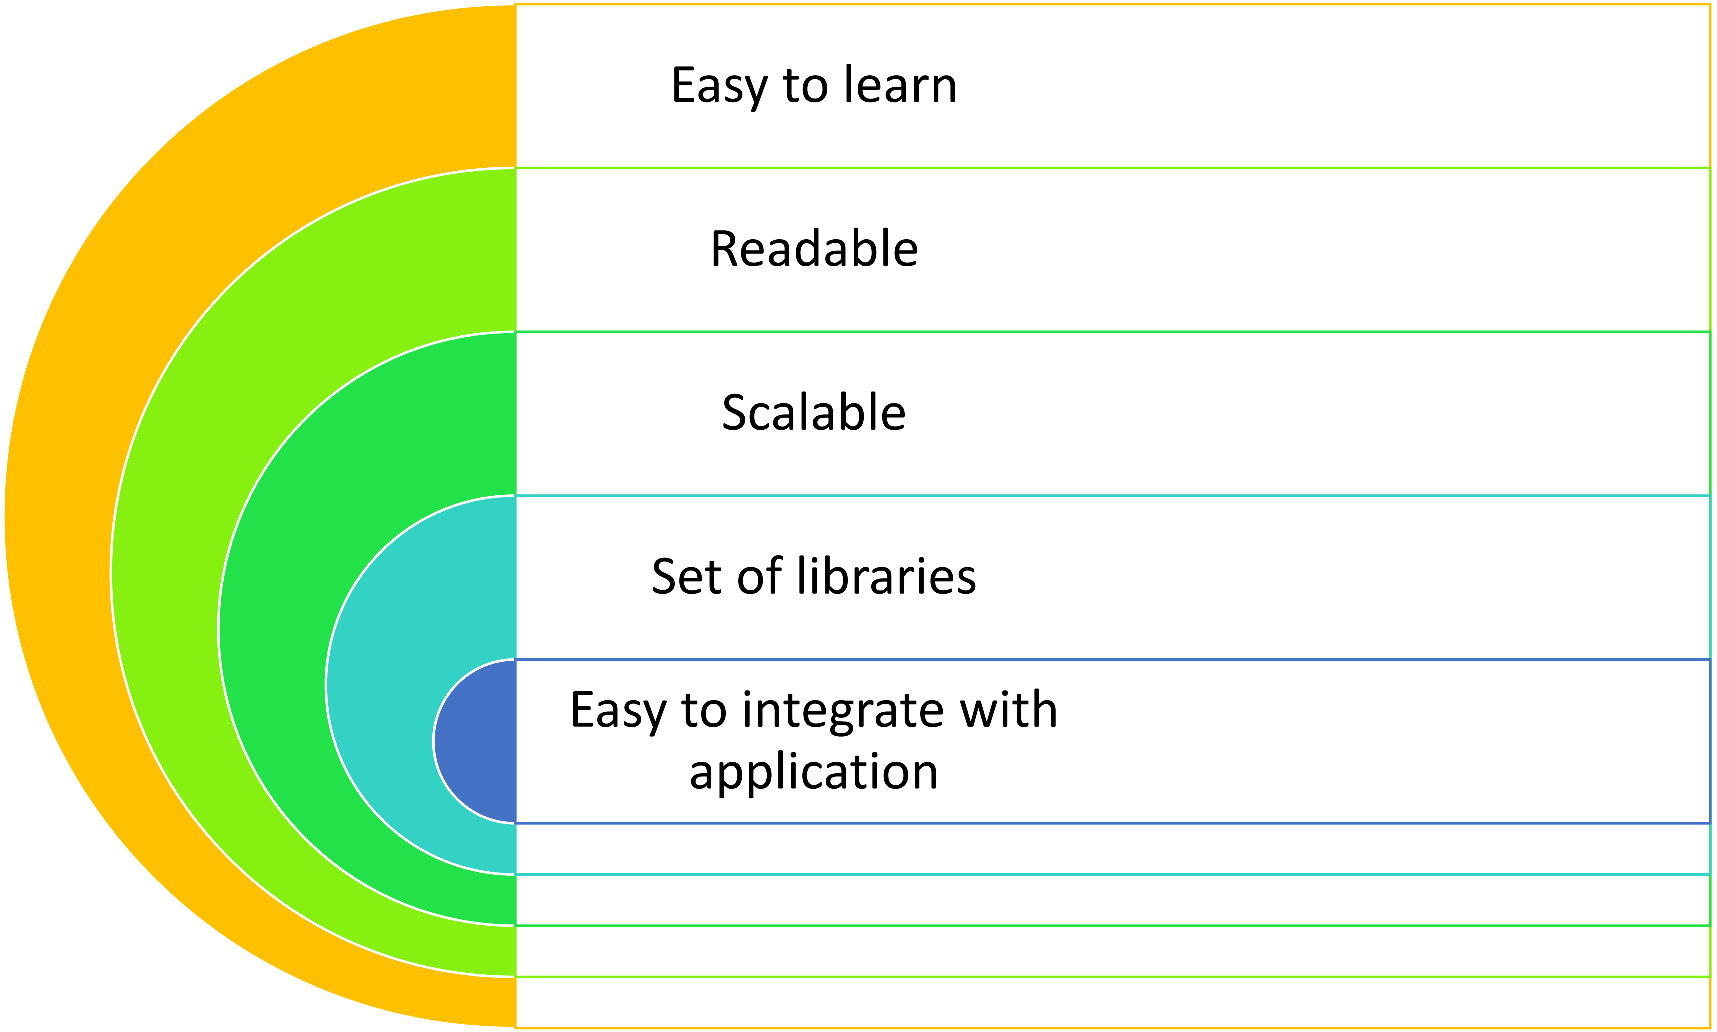

[Jesús Rogel-Salazar. DATA, 2017]
CS

Python libraries

Library	Usage
numpy, scipy	Scientific & technical computing
pandas	Data manipulation & aggregation
mlpy, scikit-learn	Machine learning
theano, tensorflow, keras	Deep learning
statsmodels	Statistical analysis
nltk, gensim	Text processing
networkx	Network analysis & visualization
bokeh, matplotlib, seaborn, plotly	Visualization
beautifulsoup, scrapy	Web scraping

CS

[Jesús Rogel-Salazar. DATA, 2017]

Component	Name
Python Version	Python 3 (vs. Python 2)
Data Analytics Environment	Jupyter Notebook
Data Analytics Software Toolkit	Anaconda (vs. Enthought Canopy)
Data Analytics Libraries	NumPy & Pandas for data analysis
	Plotly for visualization

CS

[Jesús Rogel-Salazar. DATA, 2017]

Popular Libraries

pandas	Manipulate data.
SciPy, NumPy	Scientific computing.
TensorFlow, scikit learn	Machine learning methods.
graphviz, matplotlib	Graphics.
SM StatsModels Statistics in Python	Explore data, estimate statistical models, and perform statistical test and unittest.

CS

[Jesús Rogel-Salazar. DATA, 2017]

Jupyter Python Notebook

- **Benefits of using notebooks**
  - rapid prototyping and checking intermediate results
  - Suitable for data science coding
  - Works out-of-the-box with Anaconda installed Python packages
  - Easy to share and publish
  - Can include formatted HTML using Markdown documentation inline
  - Can convert a notebook to PDF, HTML, and other formats using *jupyter nbconvert* command from the Terminal.

CS

Anaconda Python environment manager

- Download: https://www.anaconda.com/download/

CS

[Jesús Rogel-Salazar.DATA, 2017]

Python สำหรับ Data science: การติดตั้ง Anaconda Python และ Jupyter Notebook บน Windows

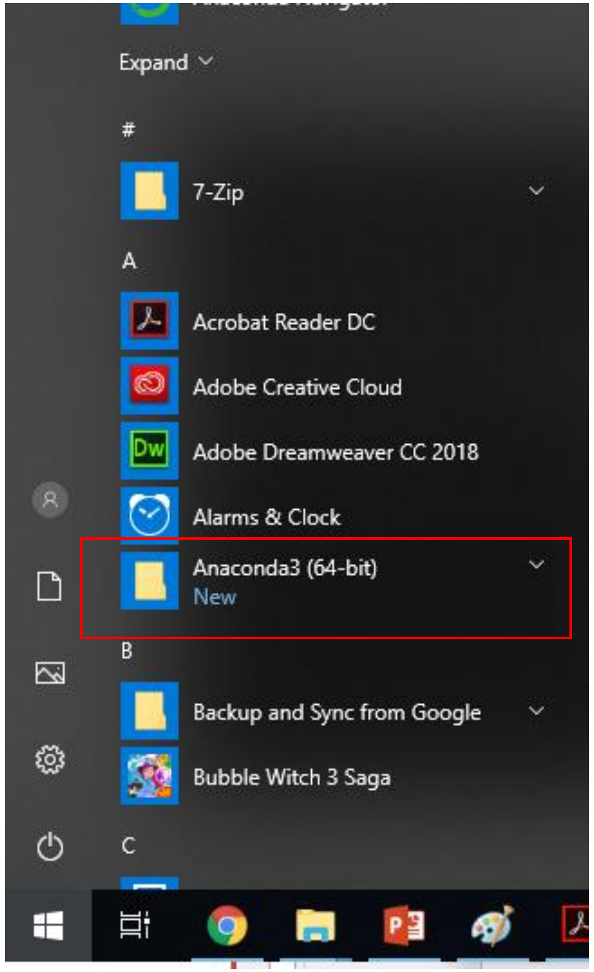

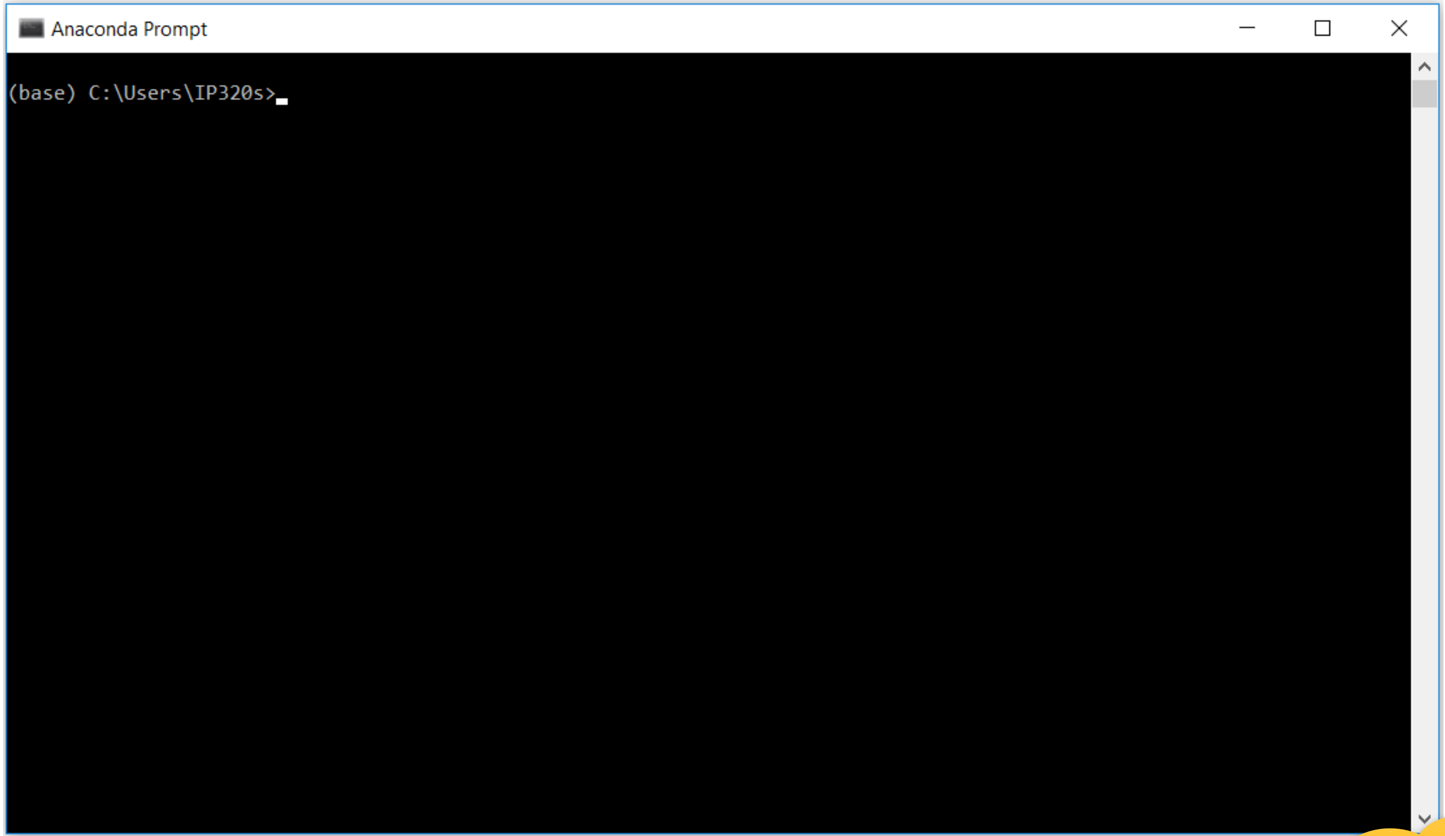

CS

[Jesús Rogel-Salazar.DATA, 2017]

Check python version

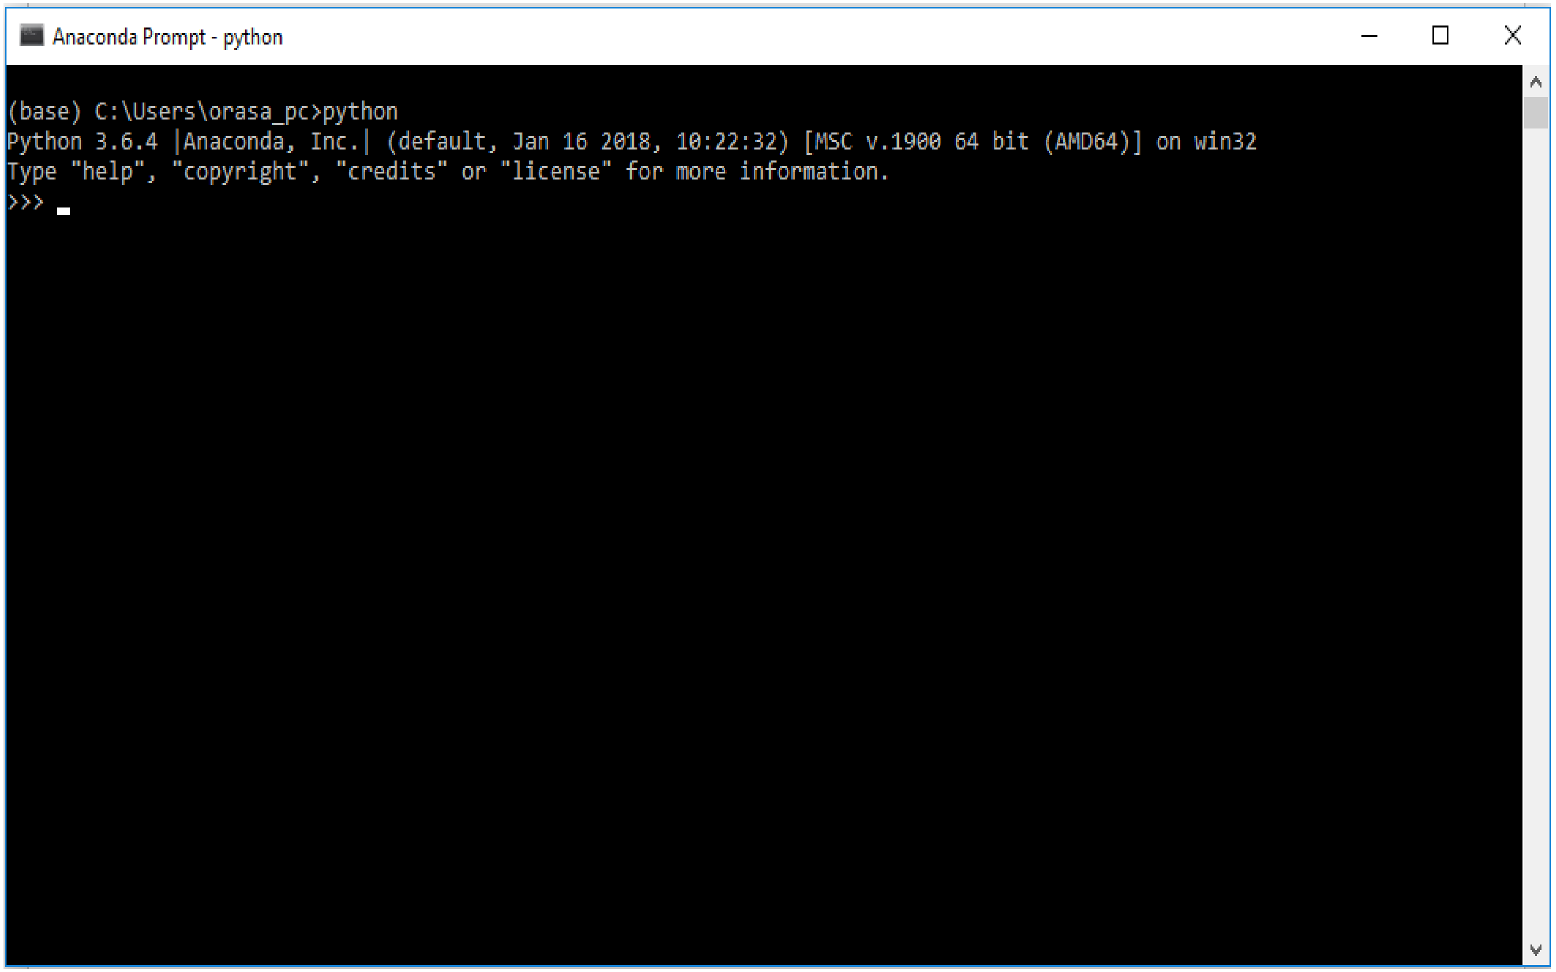

CS

Print word

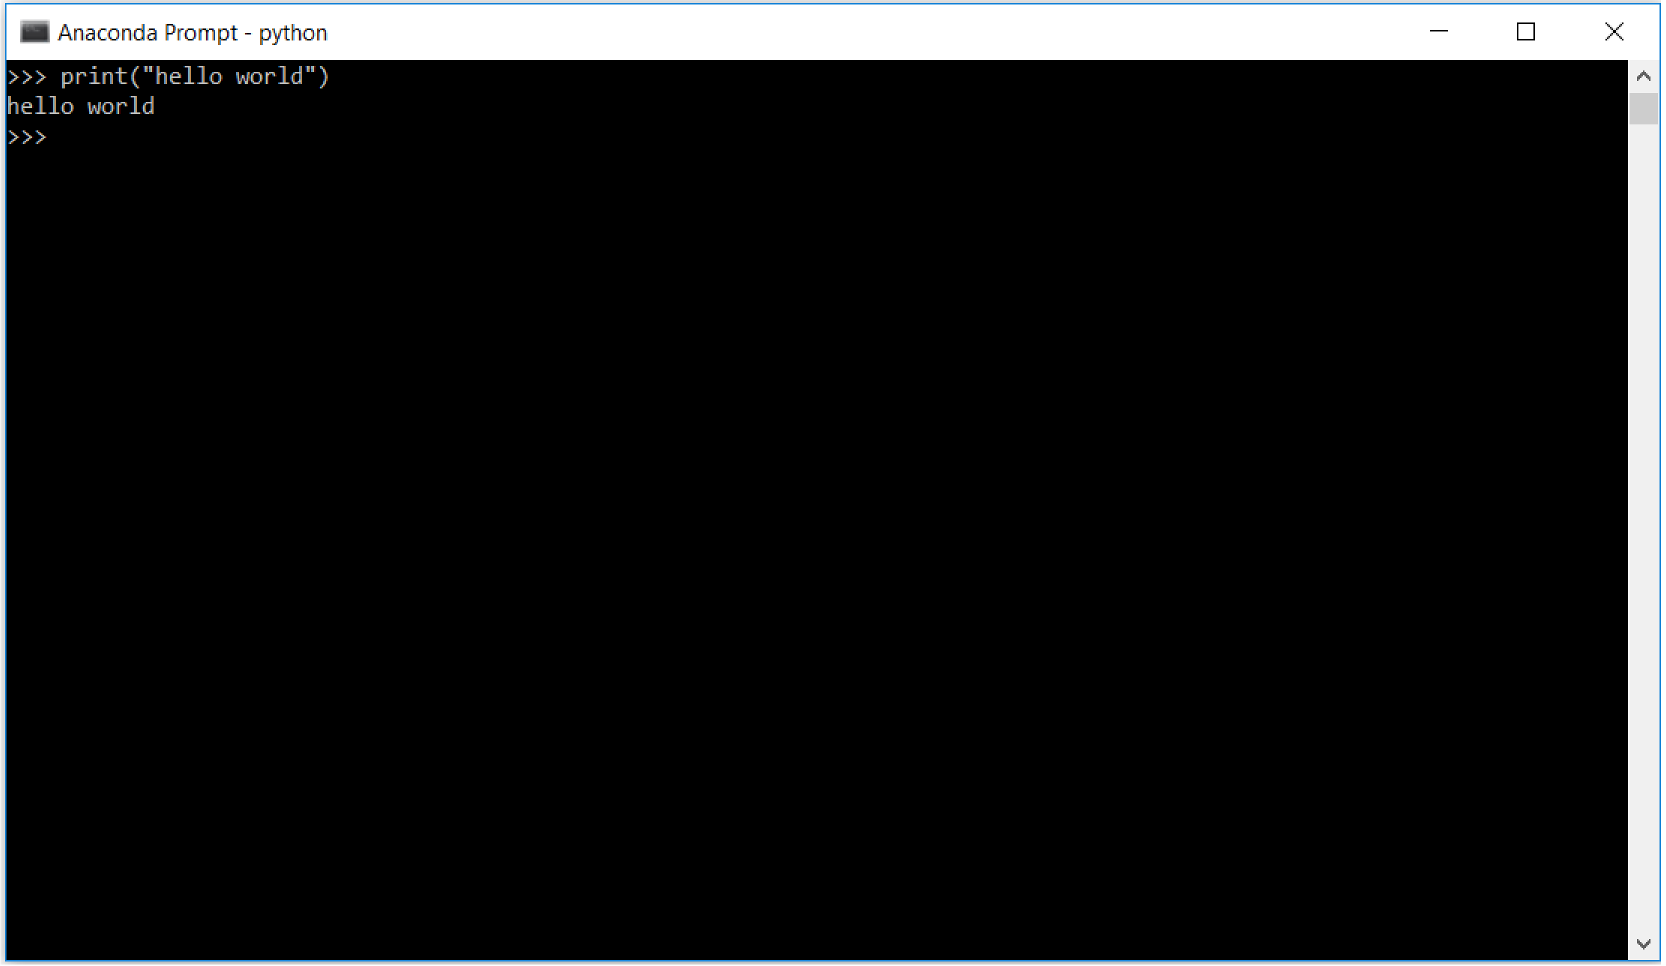

[Jesús Rogel-Salazar.DATA, 2017]

CS

Plot graph

Anaconda Prompt - python

```
(base) C:\Users\orasa_pc>python
Python 3.6.4 |Anaconda, Inc.| (default, Jan 16 2018, 10:22:32) [MSC v.1900 64 bit (AMD64)] on win32
Type "help", "copyright", "credits" or "license" for more information.
>>> import matplotlib.pyplot as plt
>>> plt.plot([2,7,3,8,4])
[<matplotlib.lines.Line2D object at 0x0000019915F8A780>]
>>> plt.show()
```

CS

Result

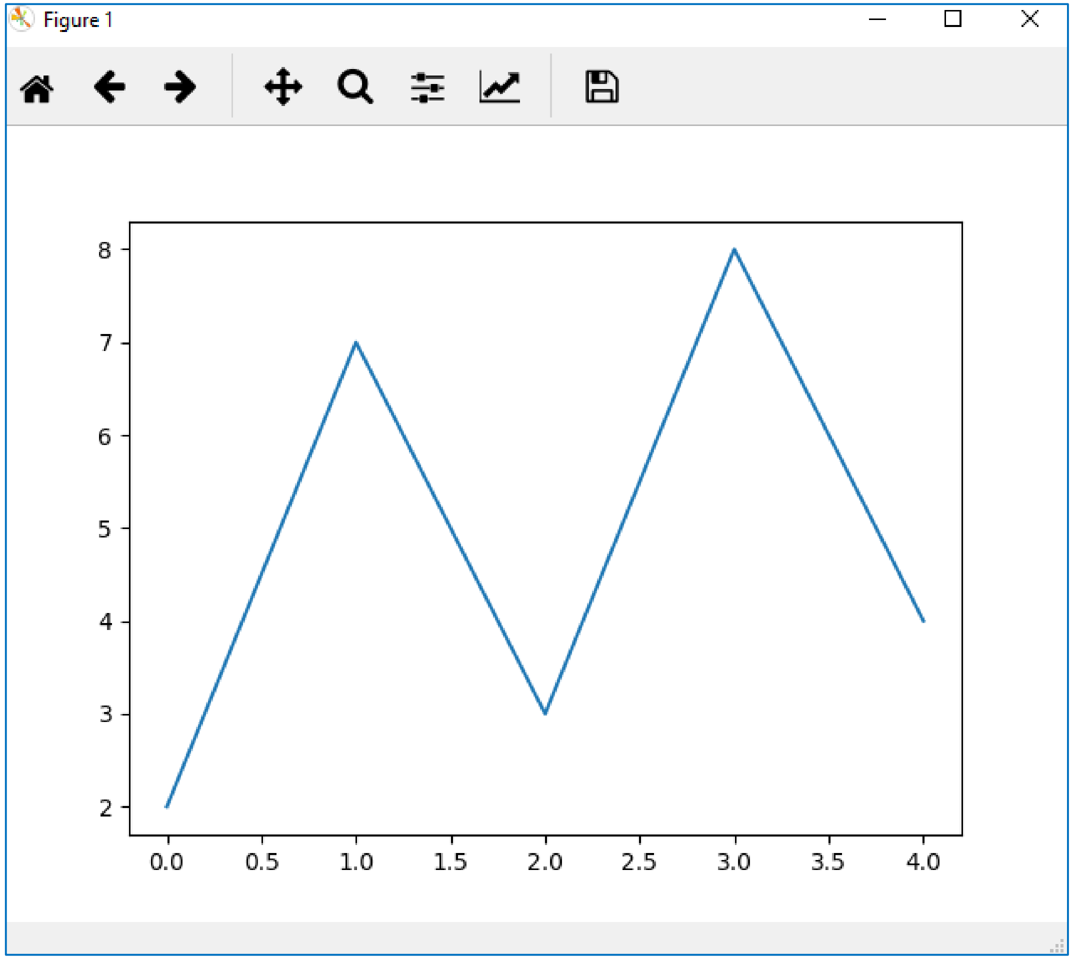

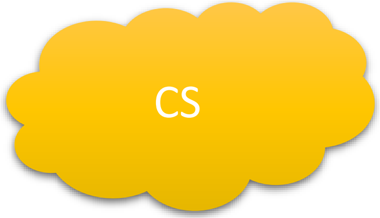

[Jesús Rogel-Salazar. DATA, 2017]

Anaconda Python environment manager

Update all packages

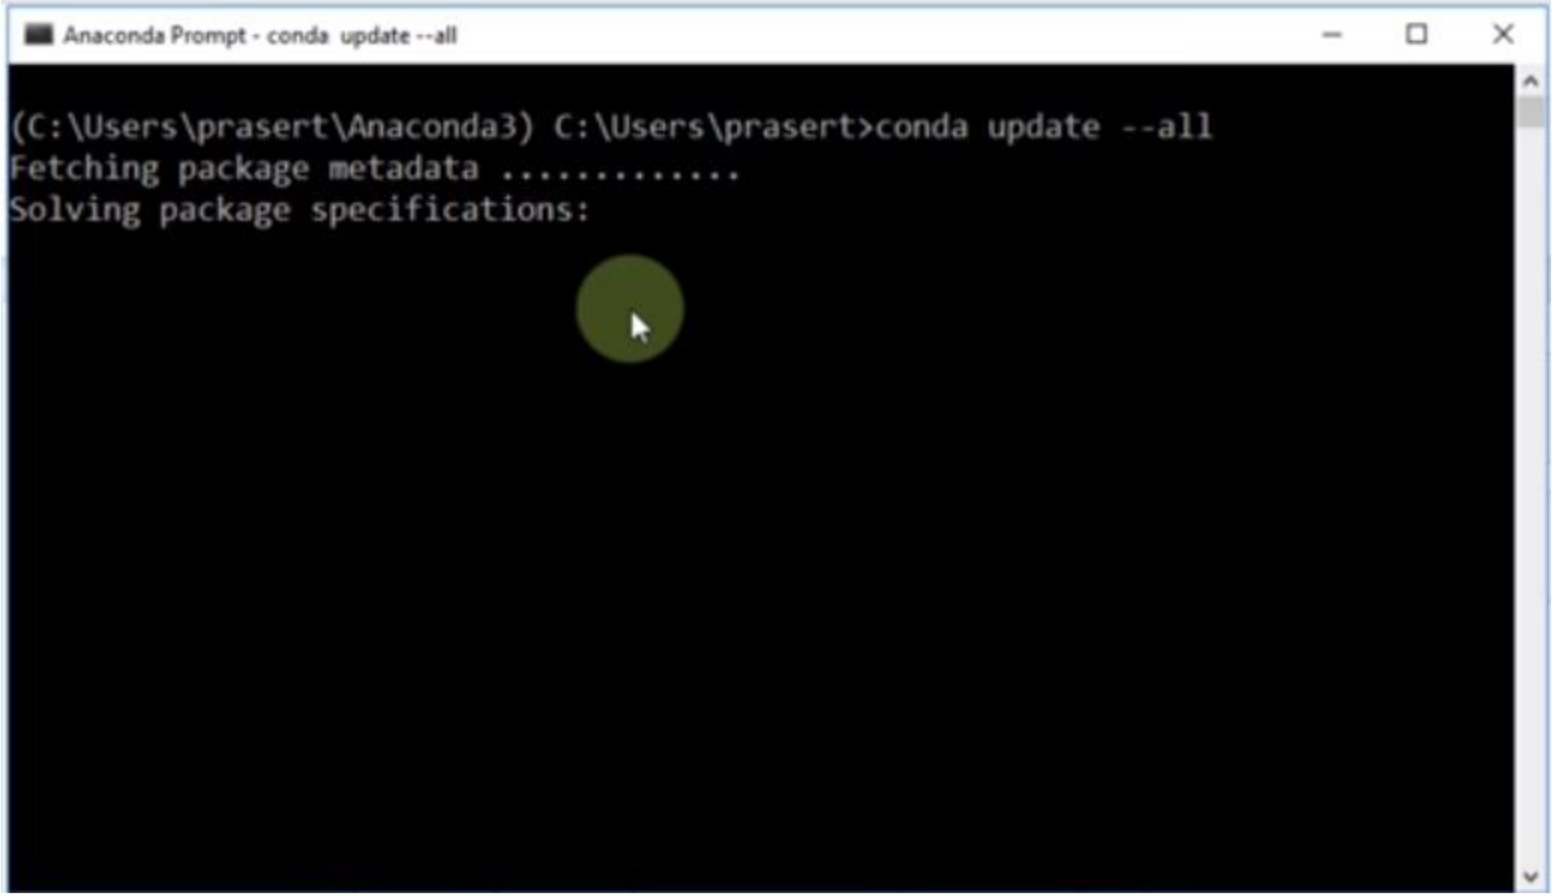

CS

[Jesús Rogel-Salazar.DATA, 2017]

Anaconda Python environment manager

Update all packages

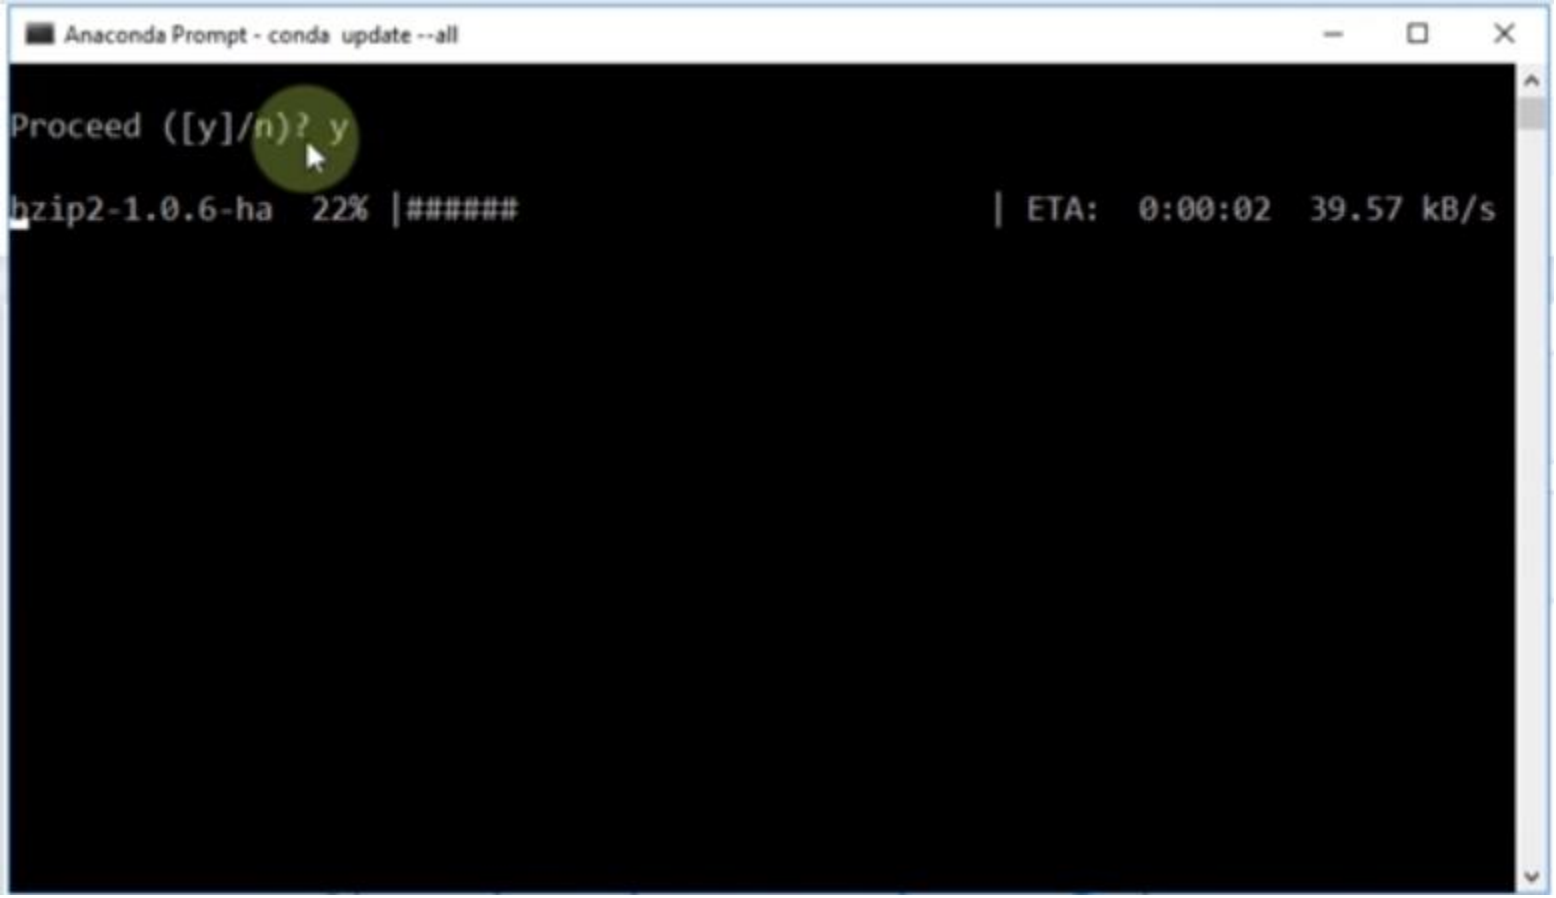

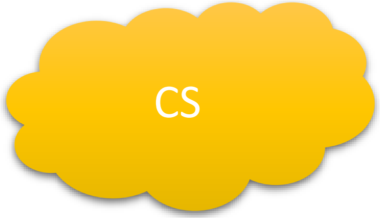

[Jesús Rogel-Salazar. DATA, 2017]

Anaconda Python environment manager

Update all packages

Anaconda Prompt - conda list

```
conda-build-3. 100% |###############################| Time: 0:00:00   2.96 MB/s
DEBUG menuinst_win32:__init__(185): Menu: name: 'Anaconda${PY_VER} ${PLATFORM}',
 prefix: 'C:\Users\prasert\Anaconda3', env_name: 'None', mode: 'None', used_mode
: 'user'
DEBUG menuinst_win32:create(299): Shortcut cmd is C:\Users\prasert\Anaconda3\pyt
hon.exe, args are ['C:\\Users\\prasert\\Anaconda3\\cwp.py', 'C:\\Users\\prasert\
\Anaconda3', 'C:\\Users\\prasert\\Anaconda3\\python.exe', 'C:\\Users\\prasert\\A
naconda3\\Scripts\\jupyter-notebook-script.py', '%USERPROFILE%']
DEBUG menuinst_win32:__init__(185): Menu: name: 'Anaconda${PY_VER} ${PLATFORM}',
 prefix: 'C:\Users\prasert\Anaconda3', env_name: 'None', mode: 'None', used_mode
: 'user'
DEBUG menuinst_win32:create(299): Shortcut cmd is C:\Users\prasert\Anaconda3\pyt
hon.exe, args are ['C:\\Users\\prasert\\Anaconda3\\cwp.py', 'C:\\Users\\prasert\
\Anaconda3', 'C:\\Users\\prasert\\Anaconda3\\python.exe', 'C:\\Users\\prasert\\A
naconda3\\Scripts\\jupyter-notebook-script.py', '%USERPROFILE%']

(C:\Users\prasert\Anaconda3) C:\Users\prasert>conda list
# packages in environment at C:\Users\prasert\Anaconda3:
#
```

CS

[Jesús Rogel-Salazar. DATA, 2017]

Anaconda Python environment manager

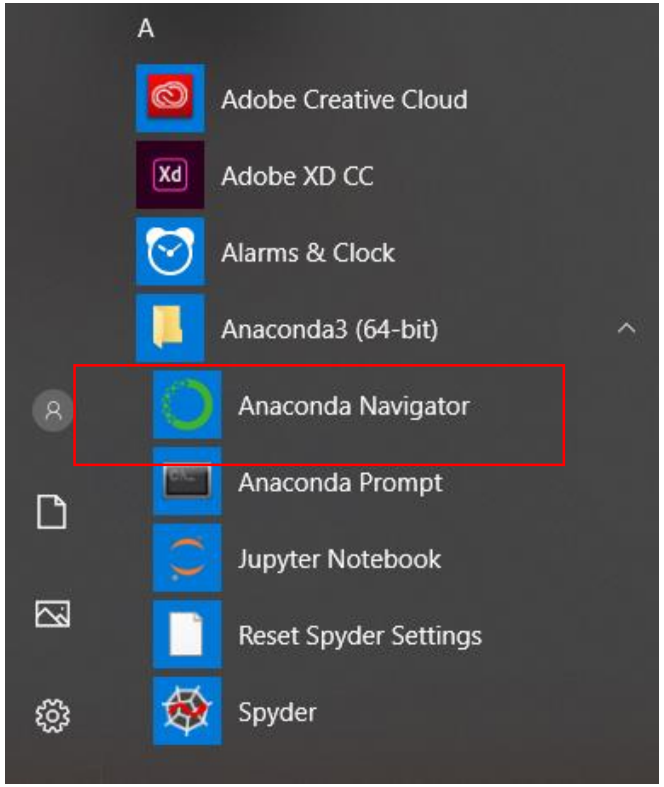

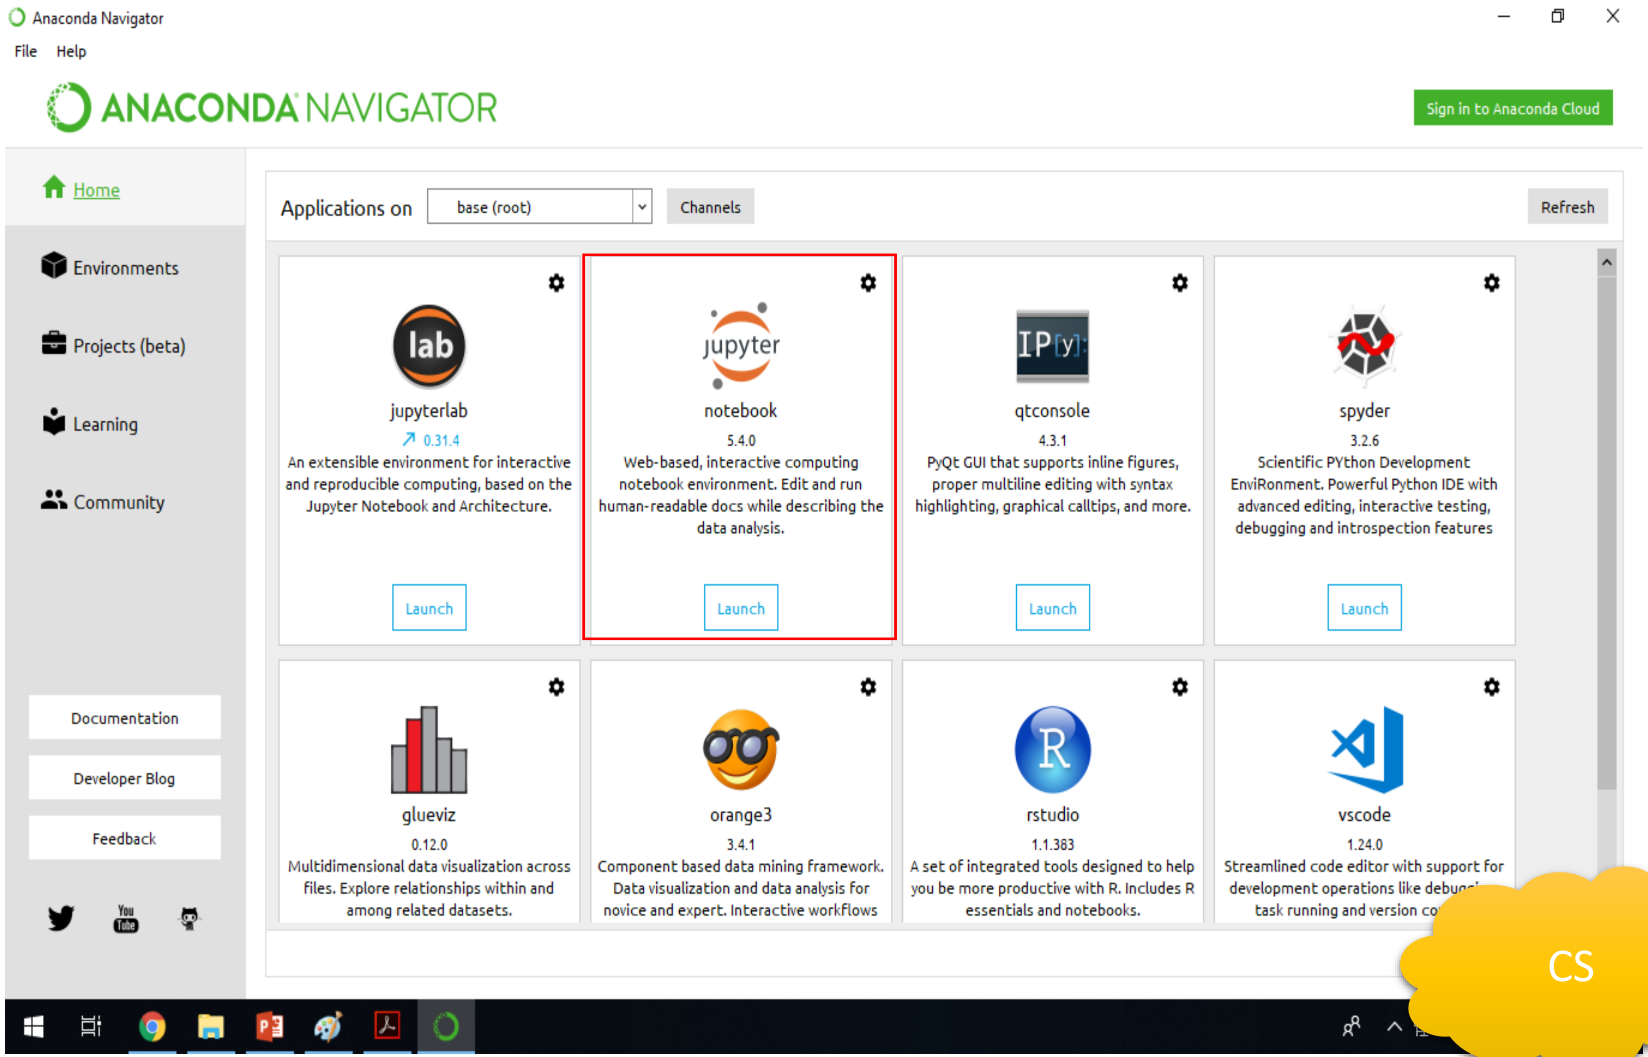

[Jesús Rogel-Salazar. DATA, 2017]

CS

Anaconda Python environment manager

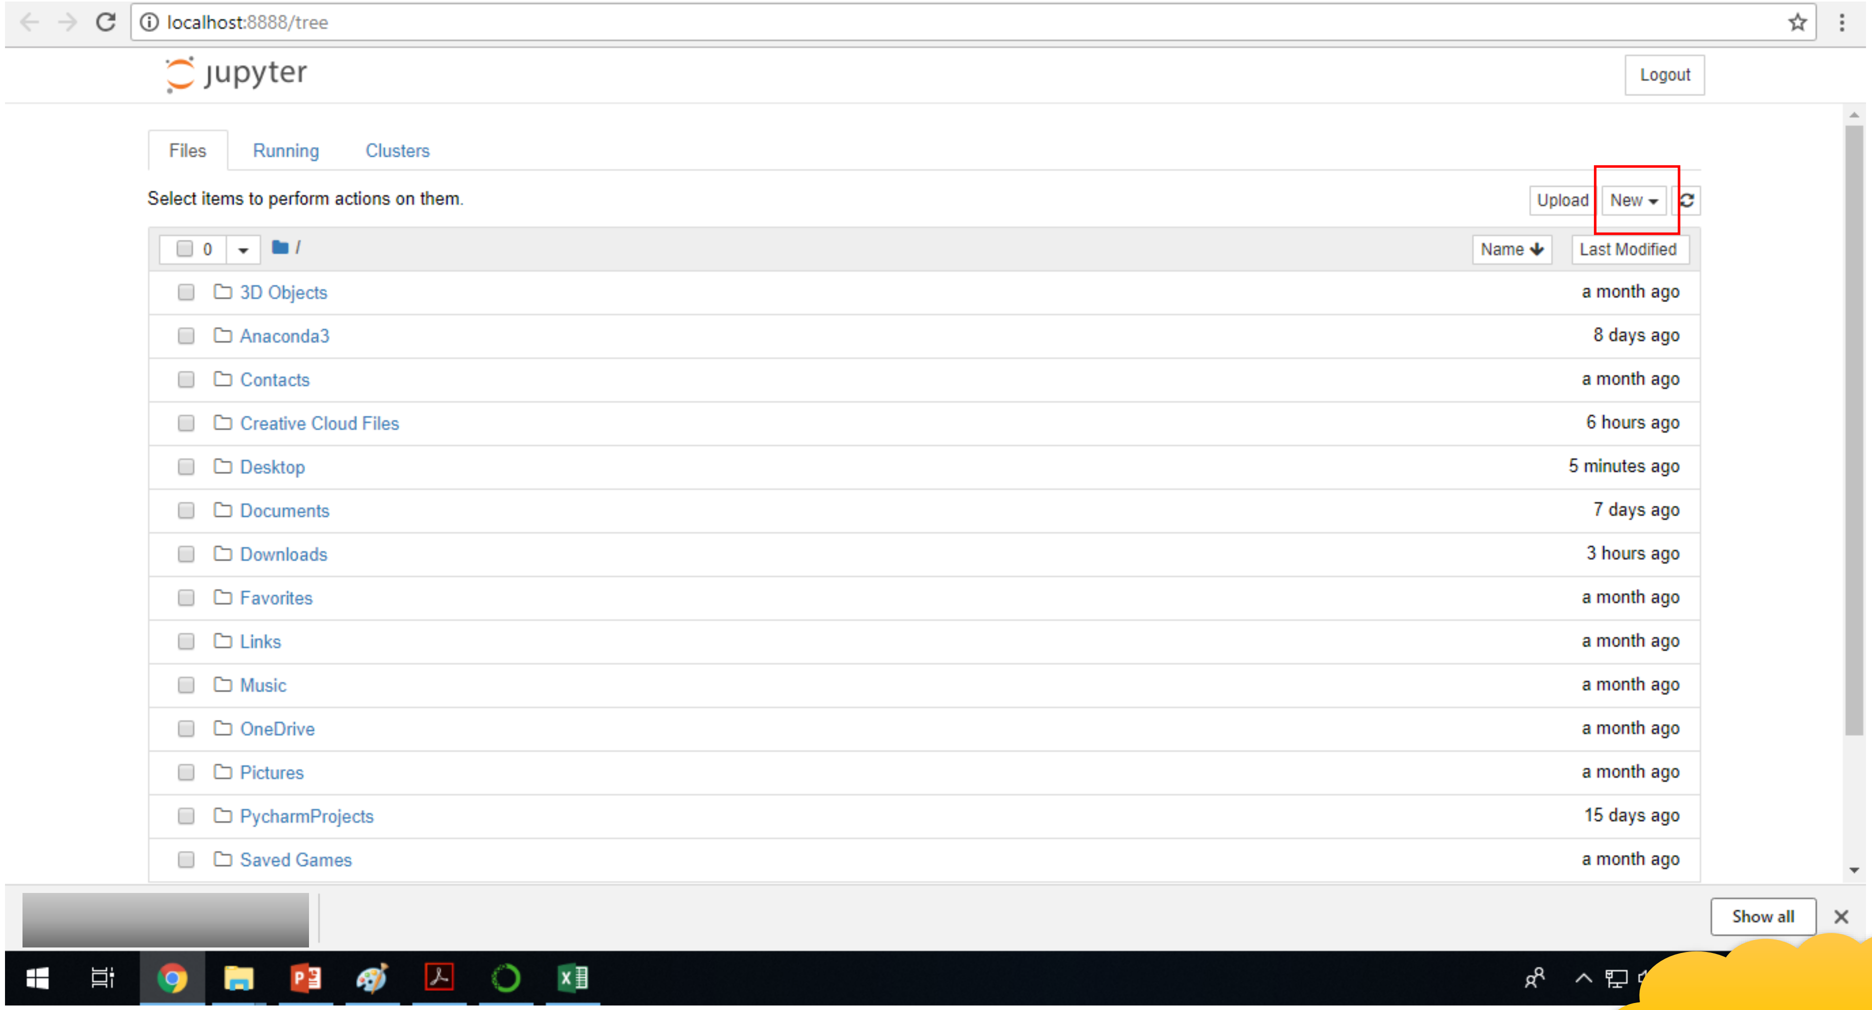

CS

Anaconda Python environment manager

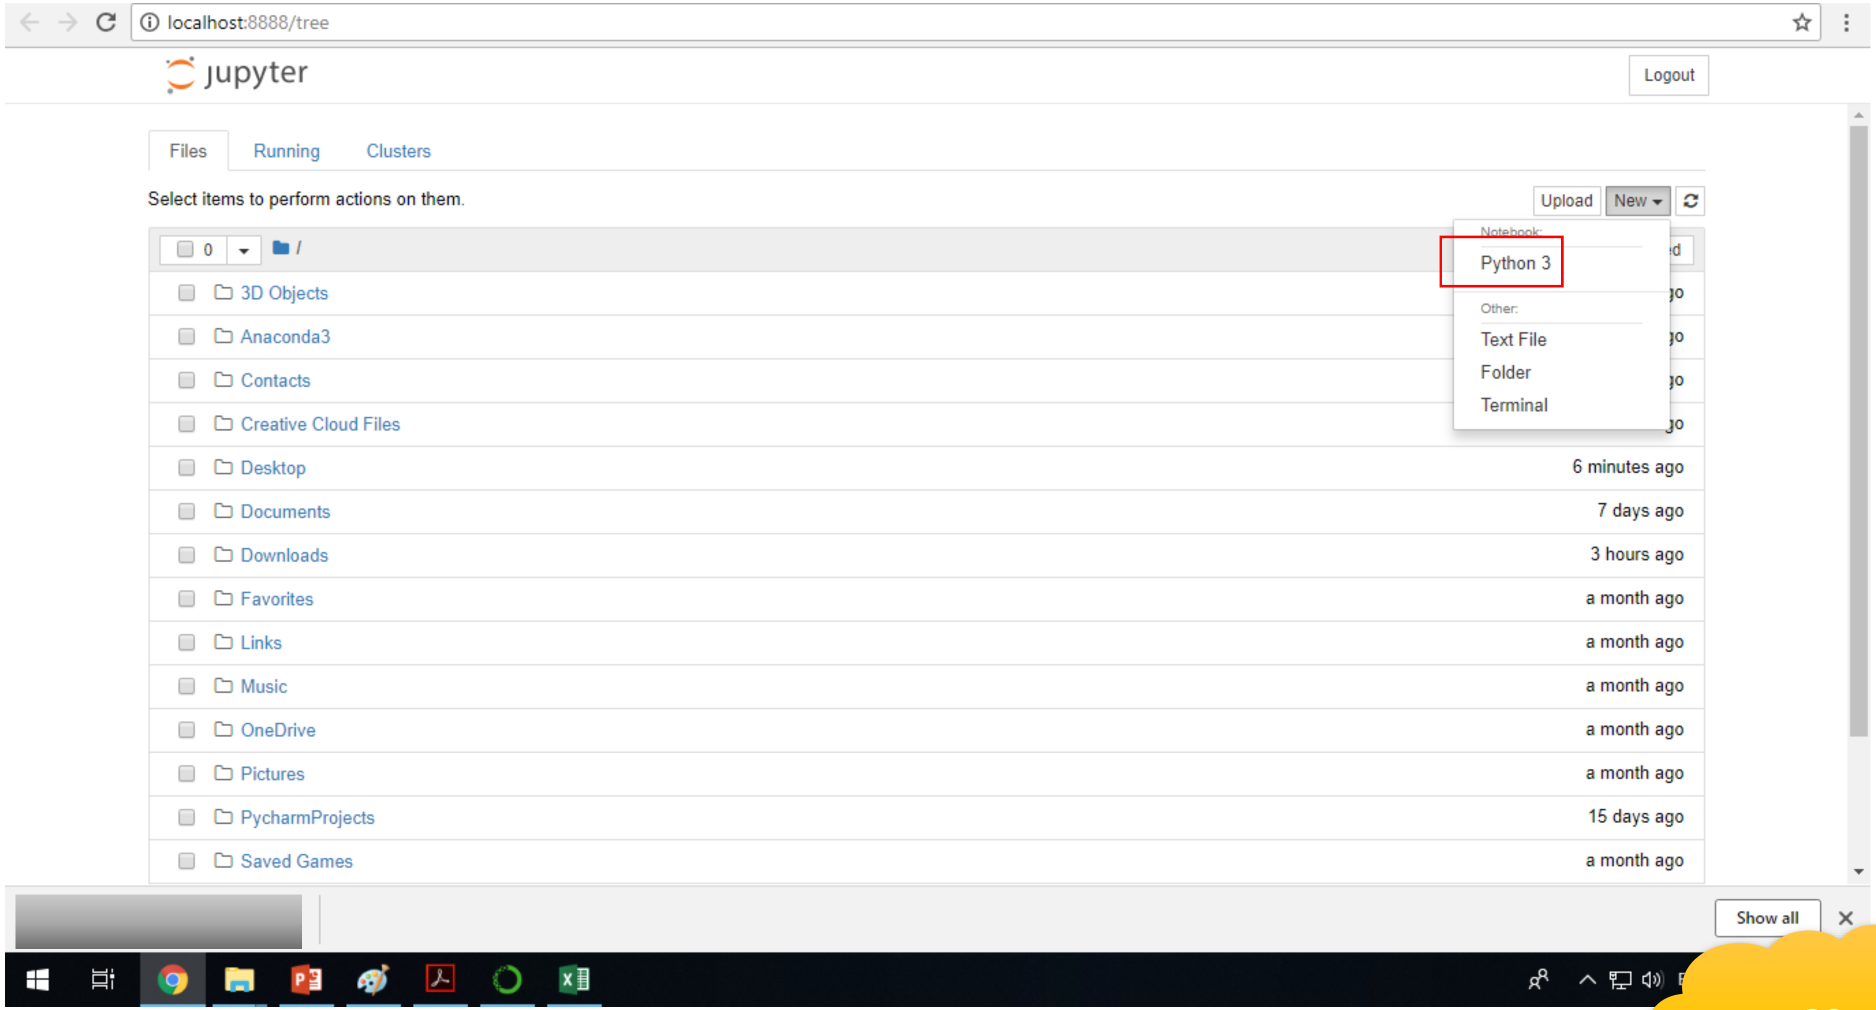

 [Jesús Rogel-Salazar. DATA, 2017]

Anaconda Python environment manager

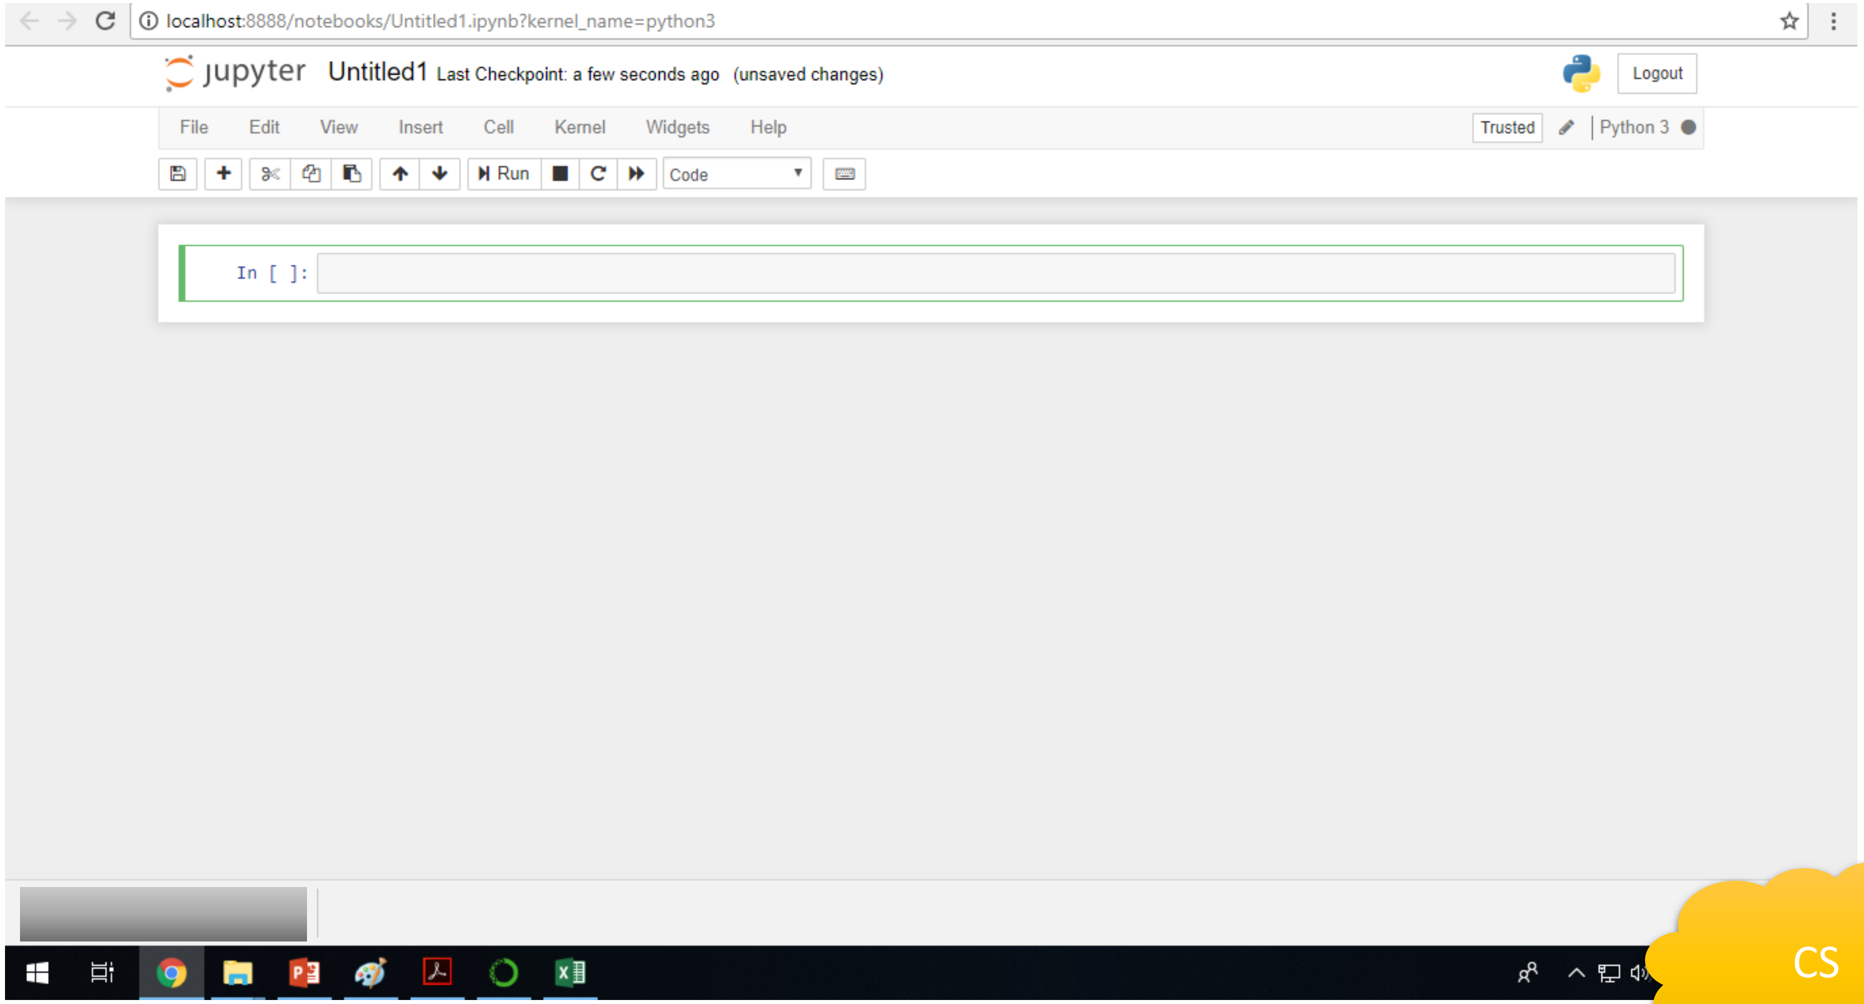

 [Jesús Rogel-Salazar. DATA, 2017]

CS

Anaconda Python environment manager

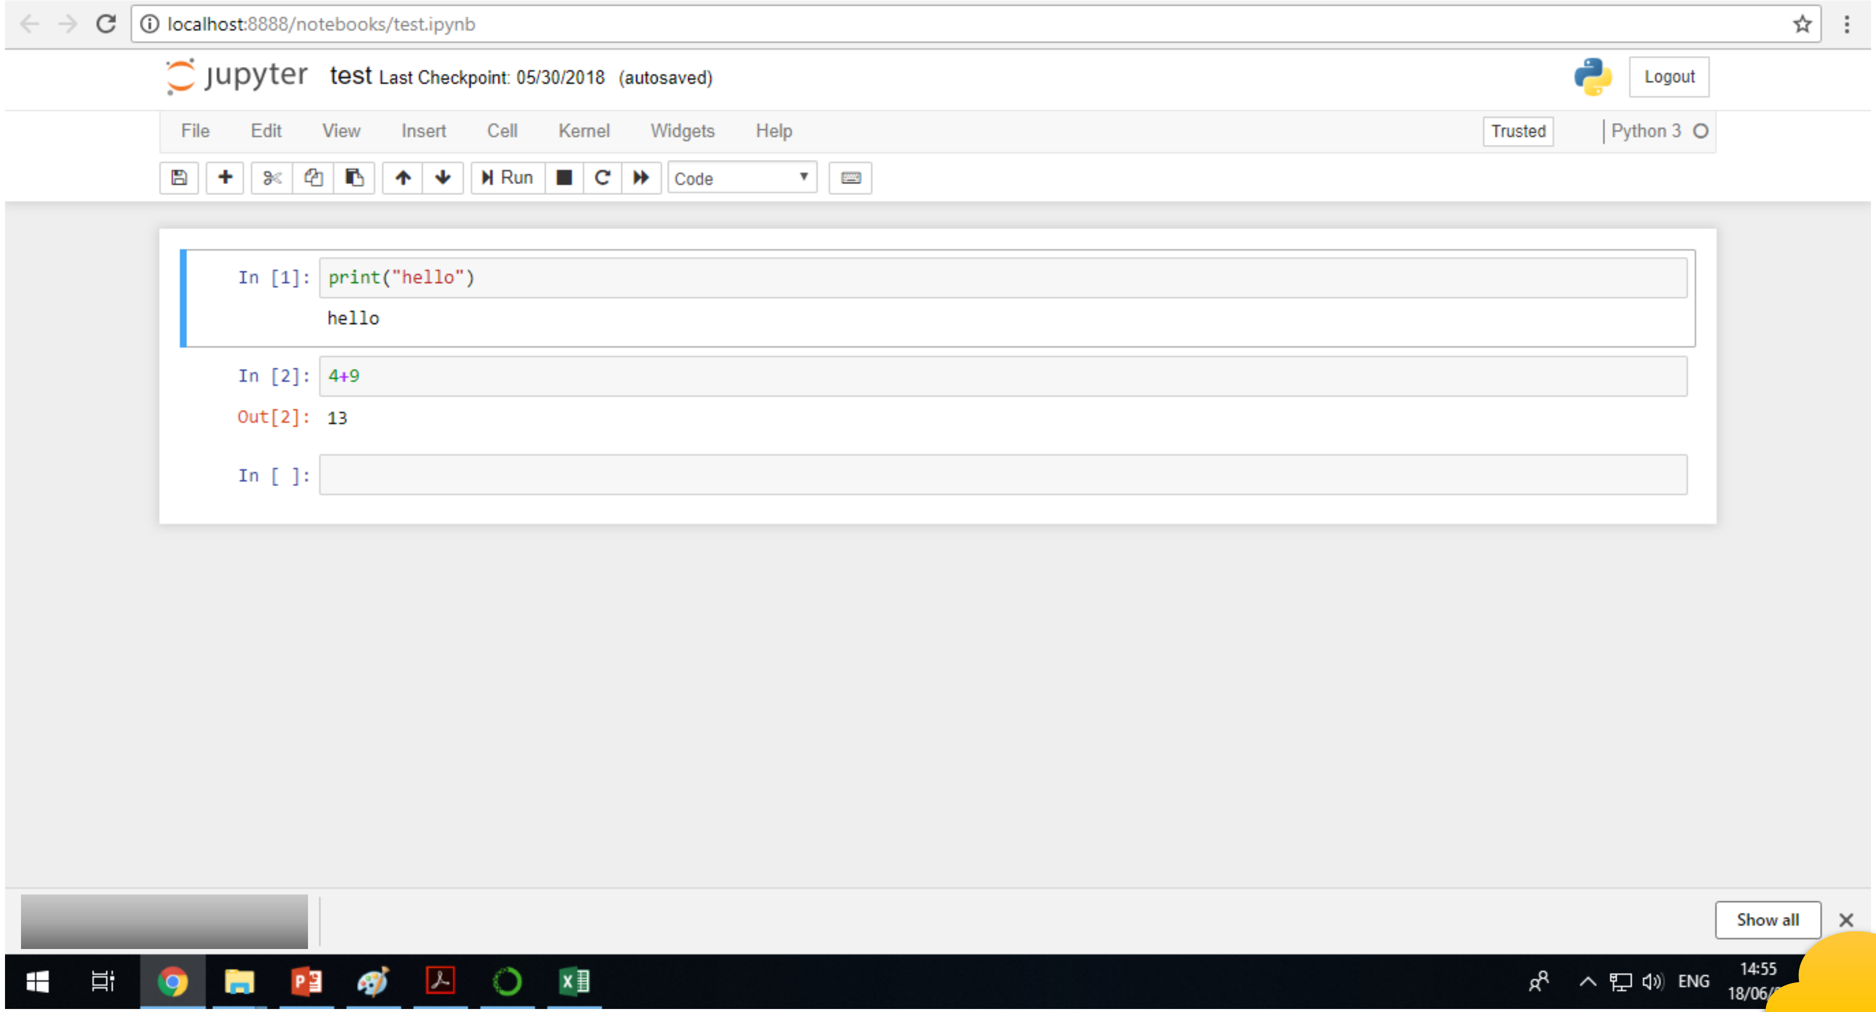

[Jesús Rogel-Salazar.DATA, 2017]

CS

Anaconda Python environment manager

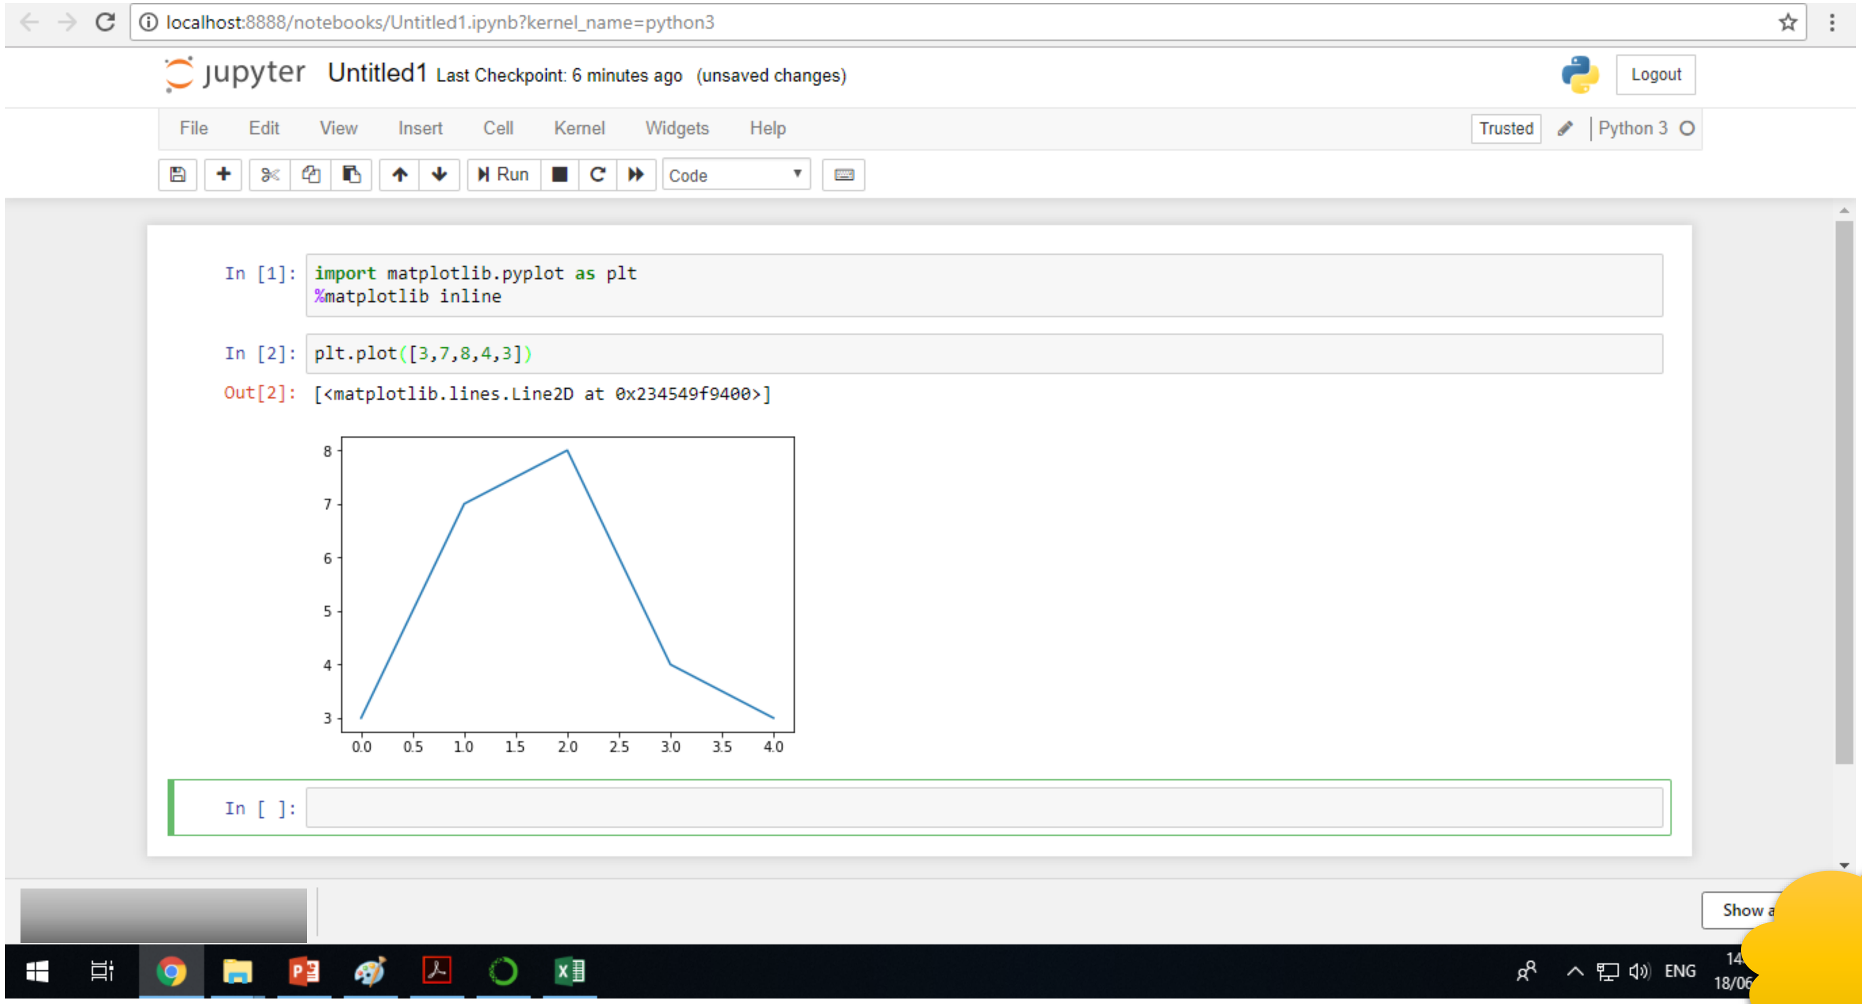

CS

[Jesús Rogel-Salazar. DATA 2017]

Anaconda Python environment manager

http://jupyter.org/

CS

ข้อดีของ Jupyter notebook

สามารถทำงานบน web application

สามารถทำงานบนหลาย platform ได้แก่ window, MC, unix

CS

[Jesús Rogel-Salazar.DATA, 2017]

Anaconda Python environment manager

องค์ประกอบของ Jupyter notebook

1. Cell สามารถใส่ code หรือ Markdown หรือ hyper link

   Code –ใส่ code

   Markdown -ใส่ข้อความหรือบรรยายสมการ

2. ในการเขียน python อาจจะใช้ตัว IDE คือ pycharm เหมาะสำหรับการสร้าง class หรือ package ขึ้นมาใหม่ ตัว ide ก็จะเหมาะกว่า ตัว IDE จะเก็บแค่ code แต่ไม่เก็บตัวผลลัพธ์ เราต้องเขียนโปรแกรมไปเรื่อยๆ มันจะไม่ได้ interactive เหมือนตัว notebook

CS

[Jesús Rogel-Salazar.DATA, 2017]

Anaconda Python environment manager

องค์ประกอบของ Jupyter notebook -- code

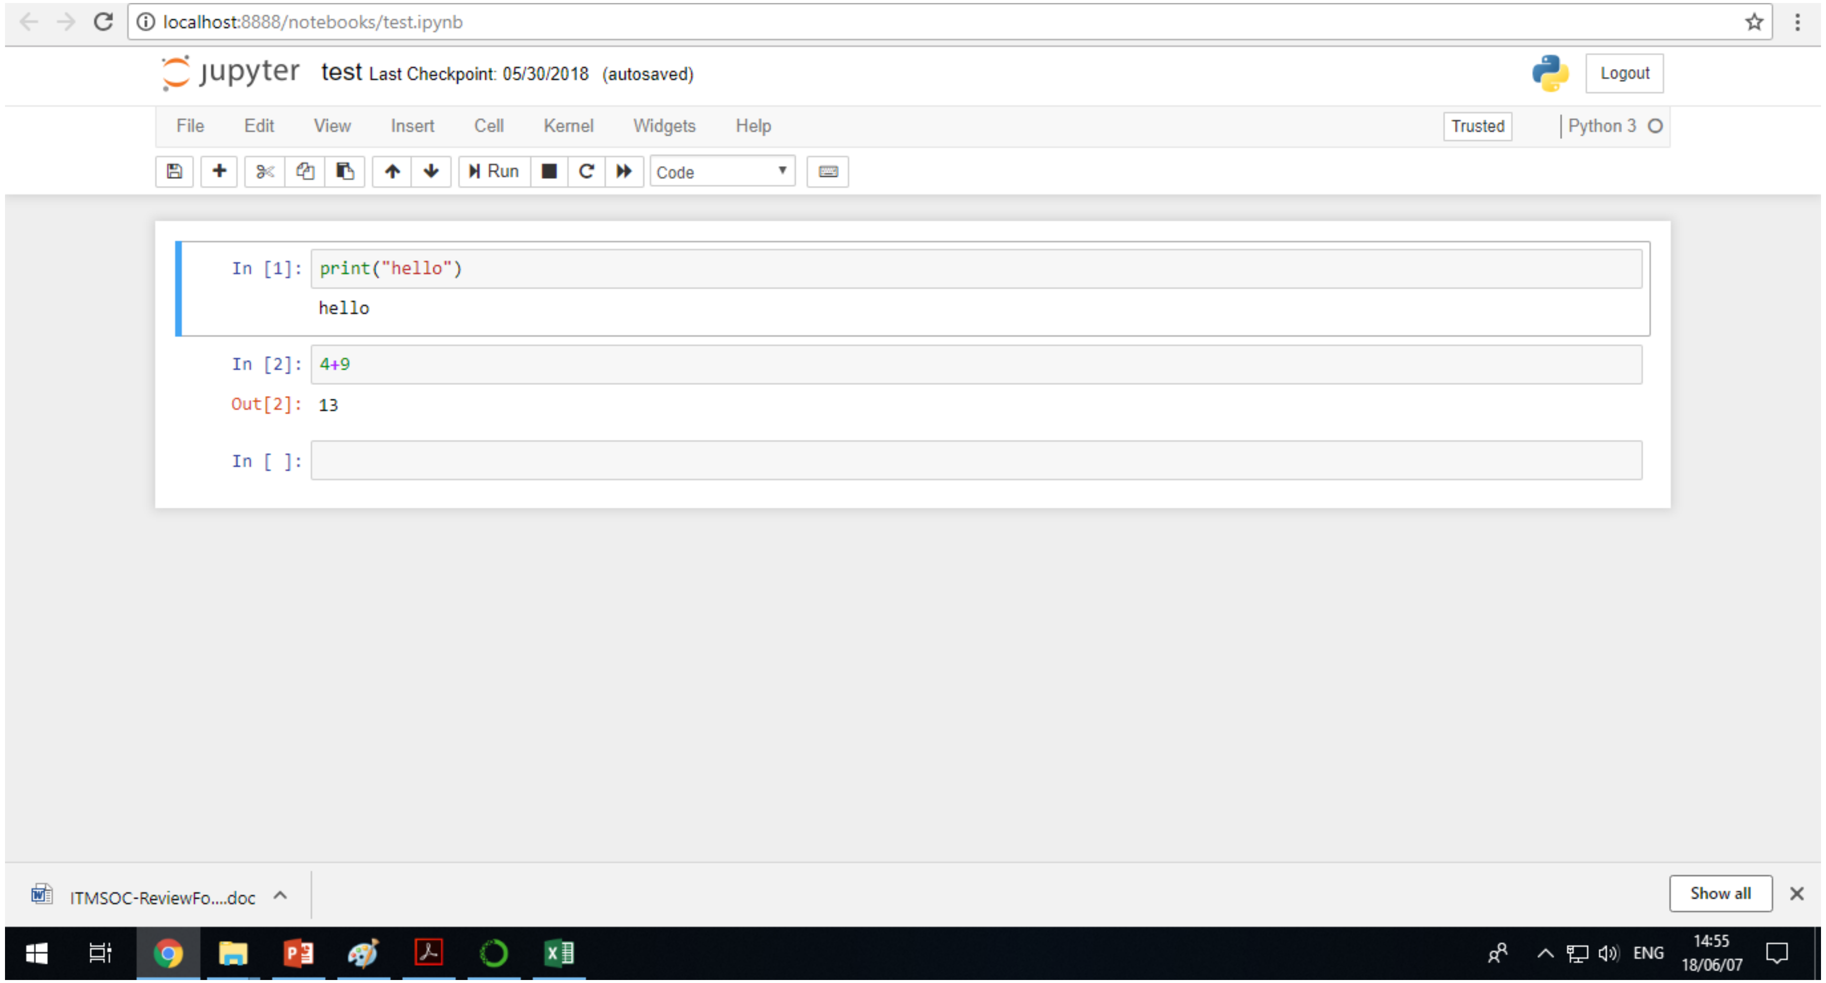

CS

[Jesús Rogel-Salazar. DATA, 2017]

Anaconda Python environment manager

องค์ประกอบของ Jupyter notebook

- ➢Cell สามารถใส่ code หรือ Markdown หรือ hyper link
  - Code –ใส่ code
  - Markdown -ใส่ข้อความหรือบรรยายสมการ

CS

[Jesús Rogel-Salazar. DATA, 2017]

Markdown

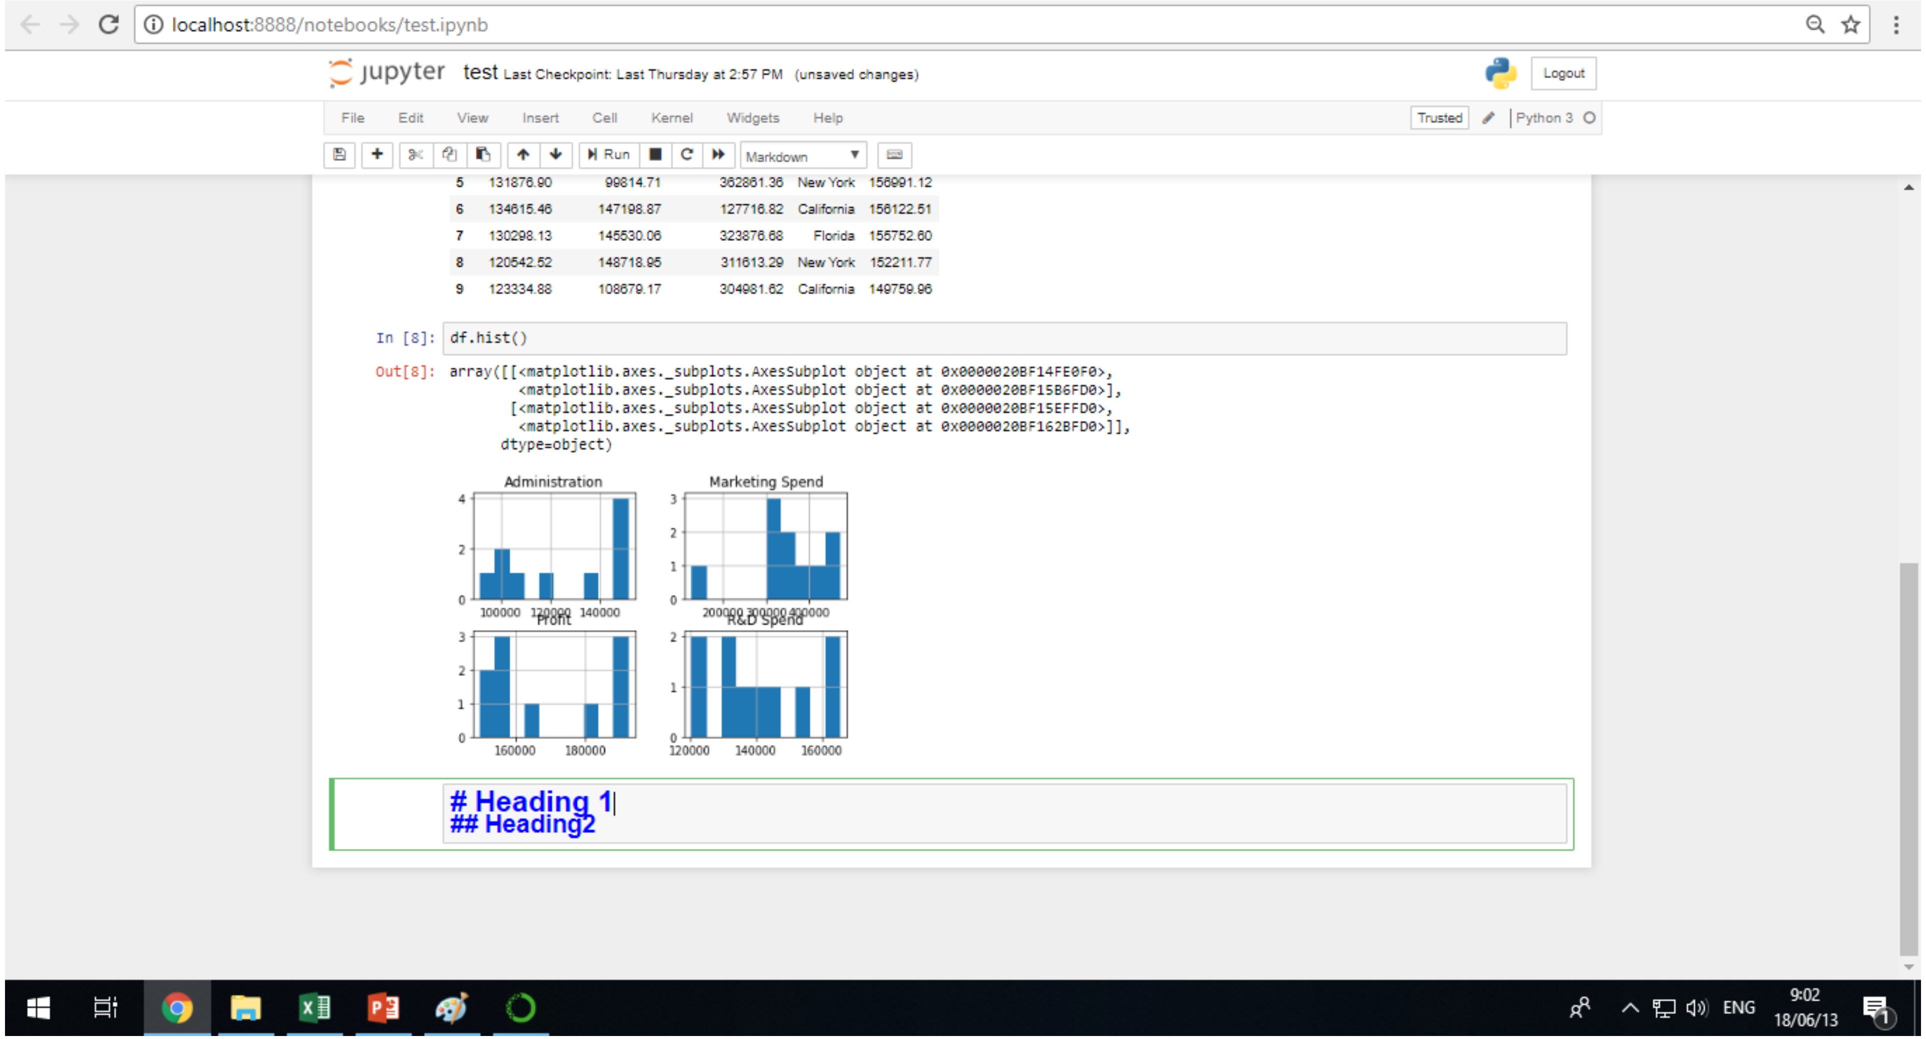

5	131876.90	99814.71	362861.36	New York	156991.12
6	134615.46	147198.87	127716.82	California	156122.51
7	130298.13	145530.06	323876.68	Florida	155752.60
8	120542.52	148718.95	311613.29	New York	152211.77
9	123334.88	108679.17	304981.62	California	149759.96

CS

[Jesús Rogel-Salazar. DATA, 2017]

Markdown

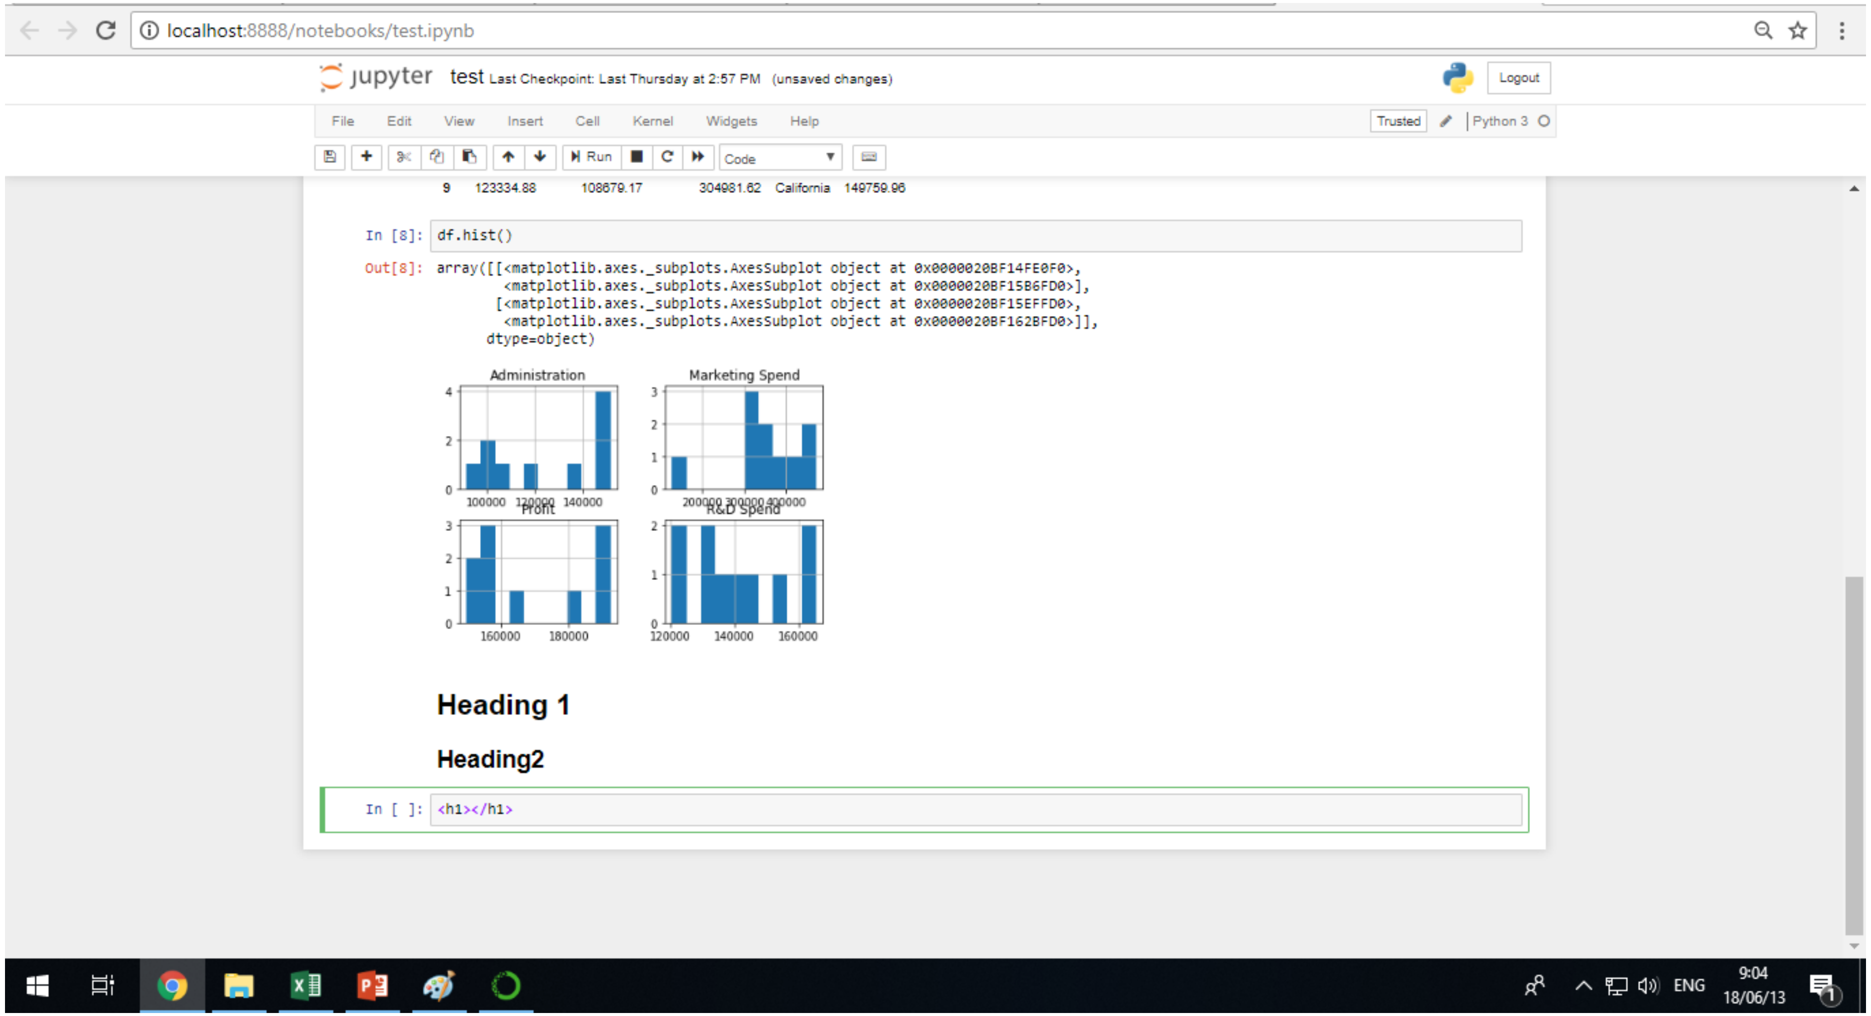

CS

[Jesús Rogel-Salazar. DATA, 2017]

Markdown

-Data science

data science

data science

CS

[Jesús Rogel-Salazar. DATA, 2017]

##Comment

```
In [9]: ## print("test")
        print ("Hello")
```

```
Hello
```

CS

[Jesús Rogel-Salazar.DATA, 2017]

spyder

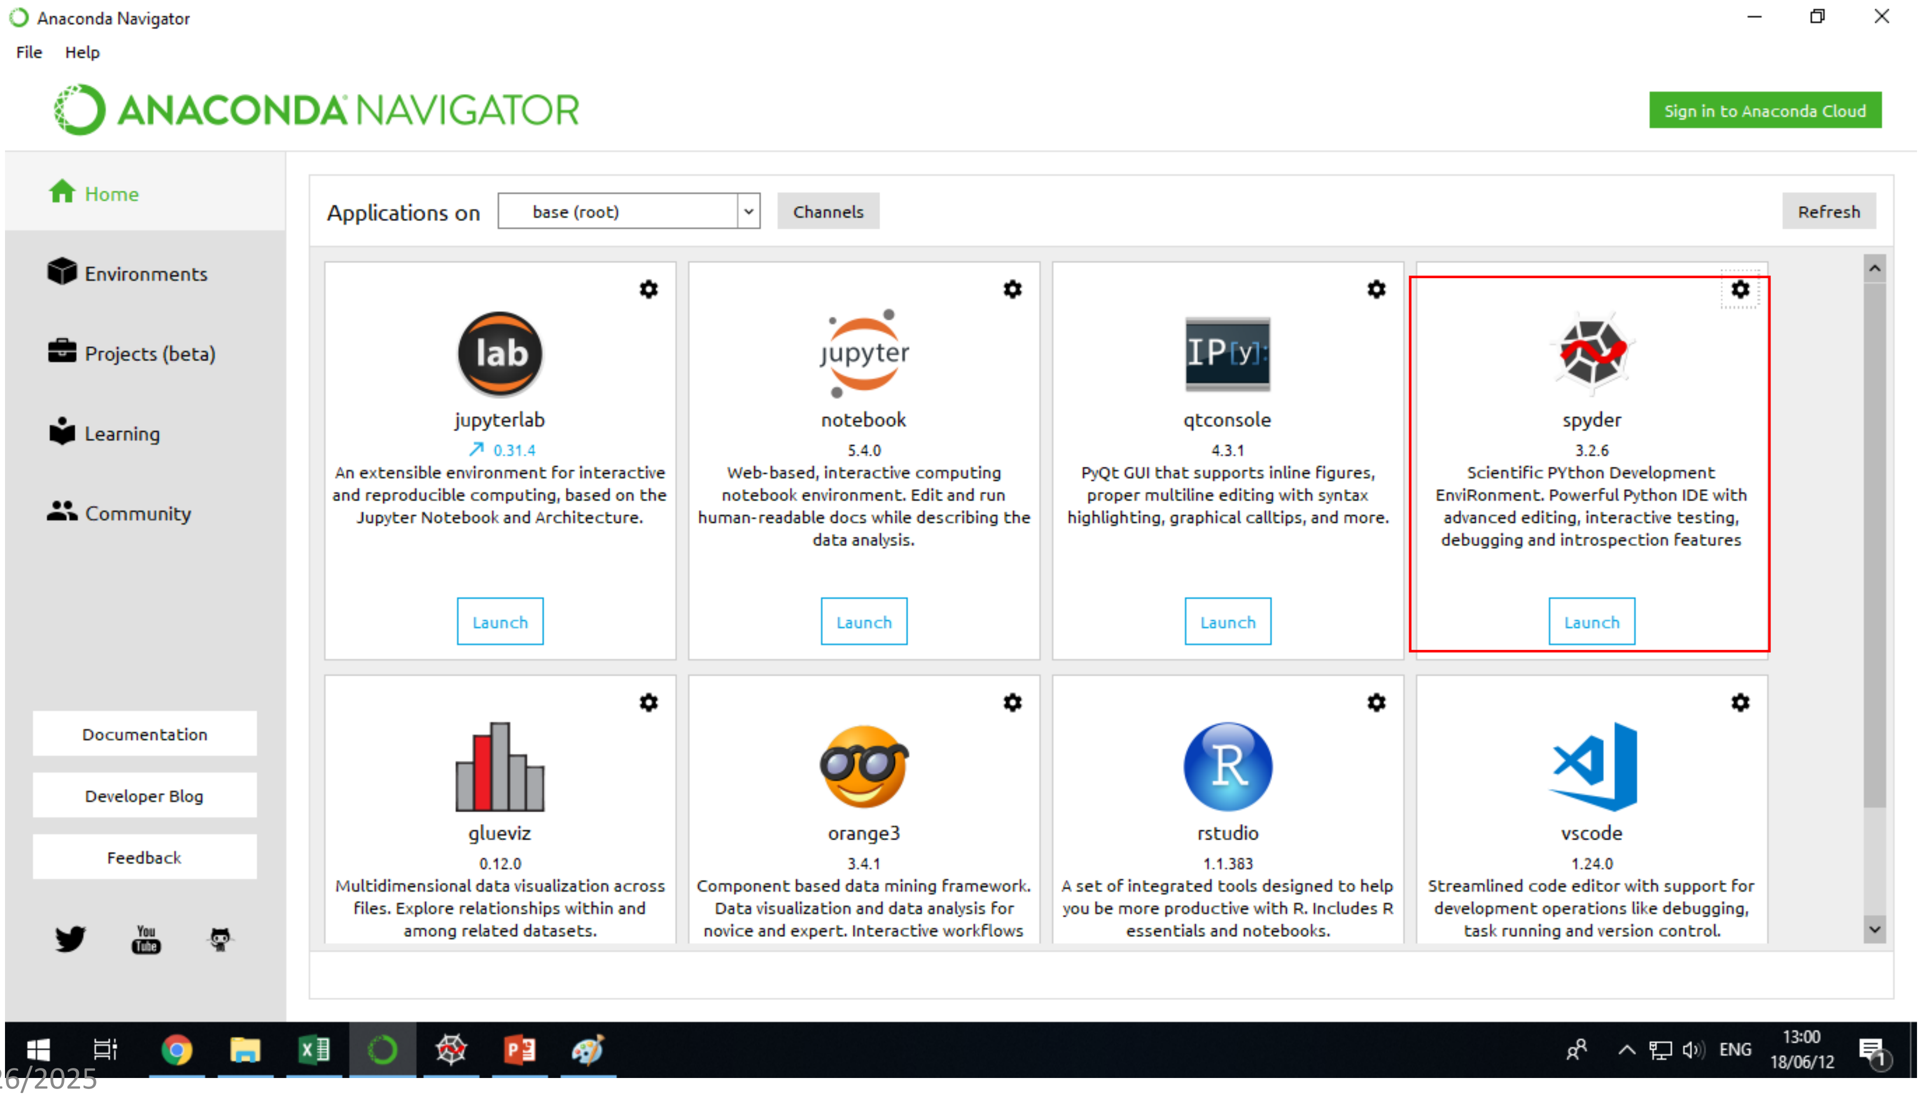
Anaconda Navigator
File Help
ANACONDA NAVIGATOR
Sign in to Anaconda Cloud
Home
Environments
Projects (beta)
Learning
Community
Documentation
Developer Blog
Feedback
Applications on base (root) Channels Refresh
jupyterlab
0.31.4
An extensible environment for interactive and reproducible computing, based on the Jupyter Notebook and Architecture.
Launch
notebook
5.4.0
Web-based, interactive computing notebook environment. Edit and run human-readable docs while describing the data analysis.
Launch
qtconsole
4.3.1
PyQt GUI that supports inline figures, proper multiline editing with syntax highlighting, graphical calltips, and more.
Launch
spyder
3.2.6
Scientific PYthon Development EnviRonment. Powerful Python IDE with advanced editing, interactive testing, debugging and introspection features
Launch
glueviz
0.12.0
Multidimensional data visualization across files. Explore relationships within and among related datasets.
orange3
3.4.1
Component based data mining framework. Data visualization and data analysis for novice and expert. Interactive workflows
rstudio
1.1.383
A set of integrated tools designed to help you be more productive with R. Includes R essentials and notebooks.
vscode
1.24.0
Streamlined code editor with support for development operations like debugging, task running and version control.
ENG
13:00
18/06/12

CS

spyder

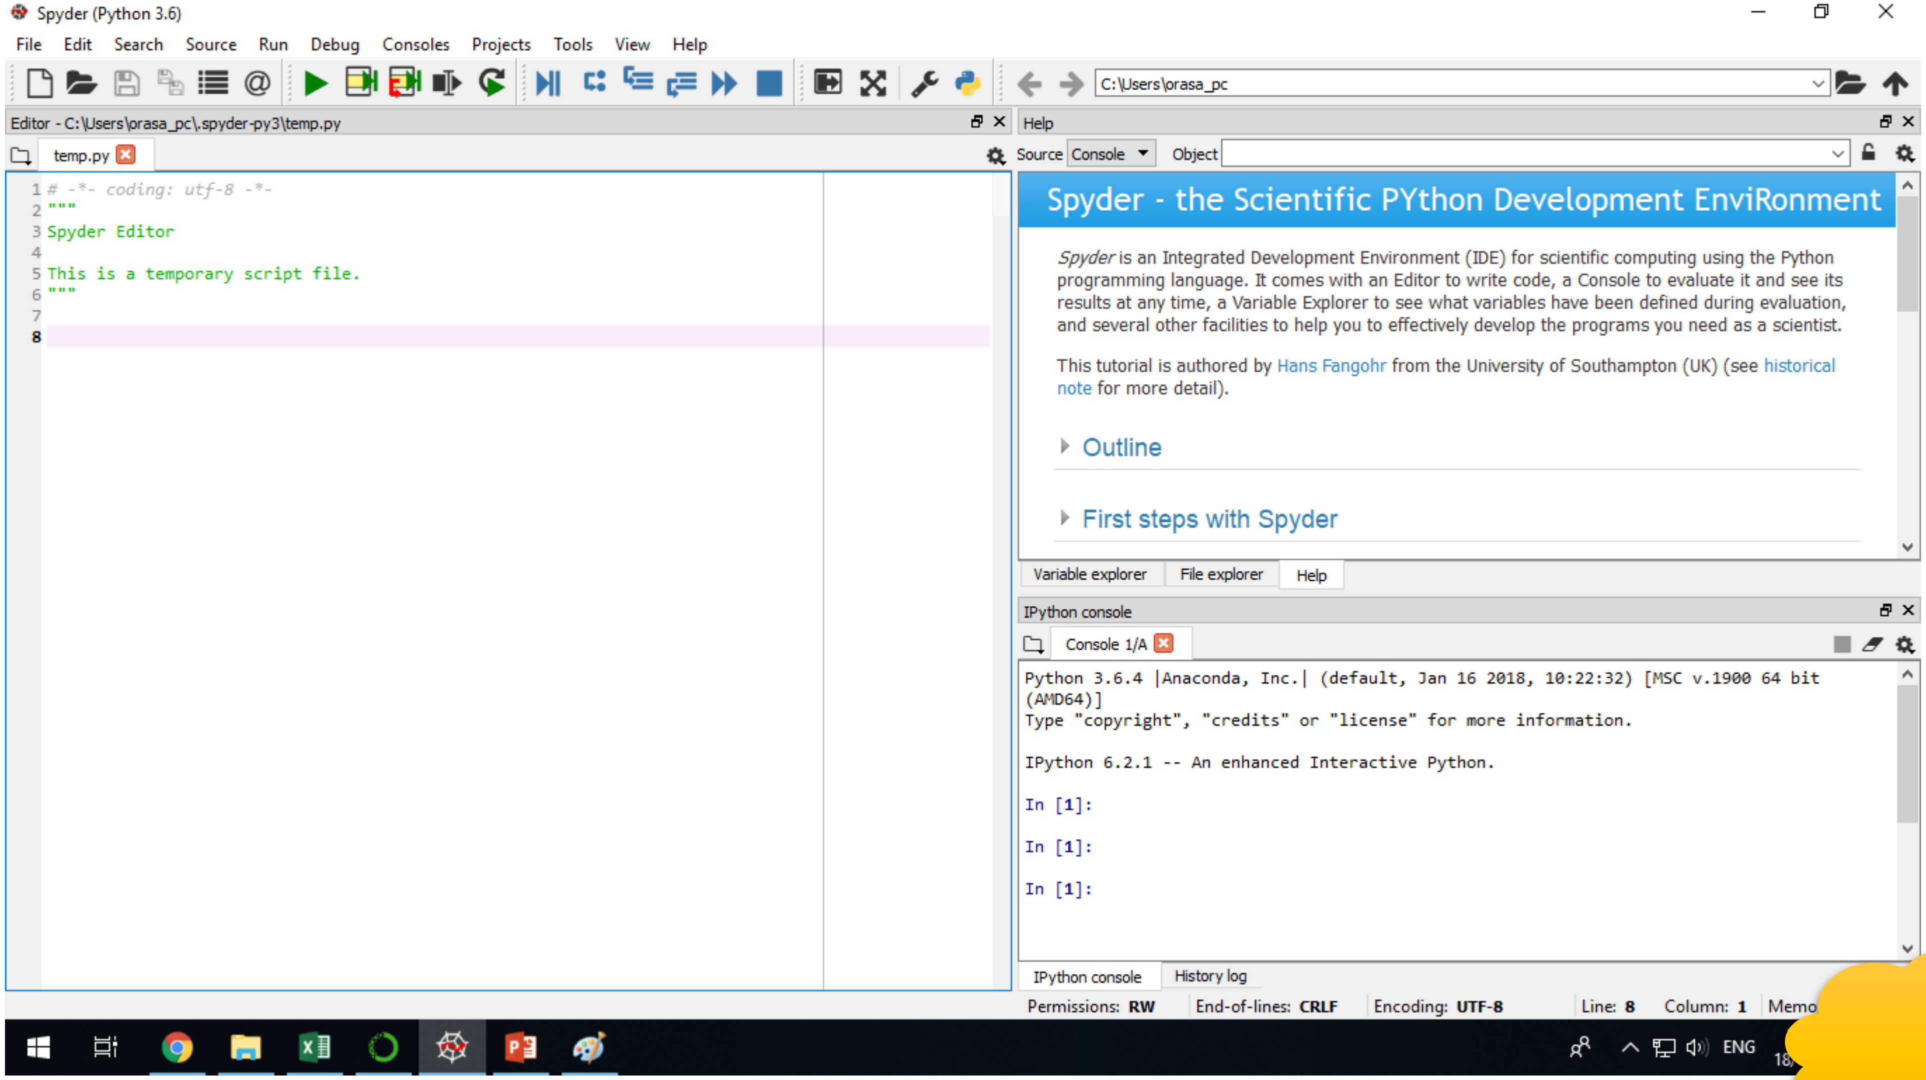

[Jesús Rogel-Salazar. DATA, 2017]

spyder

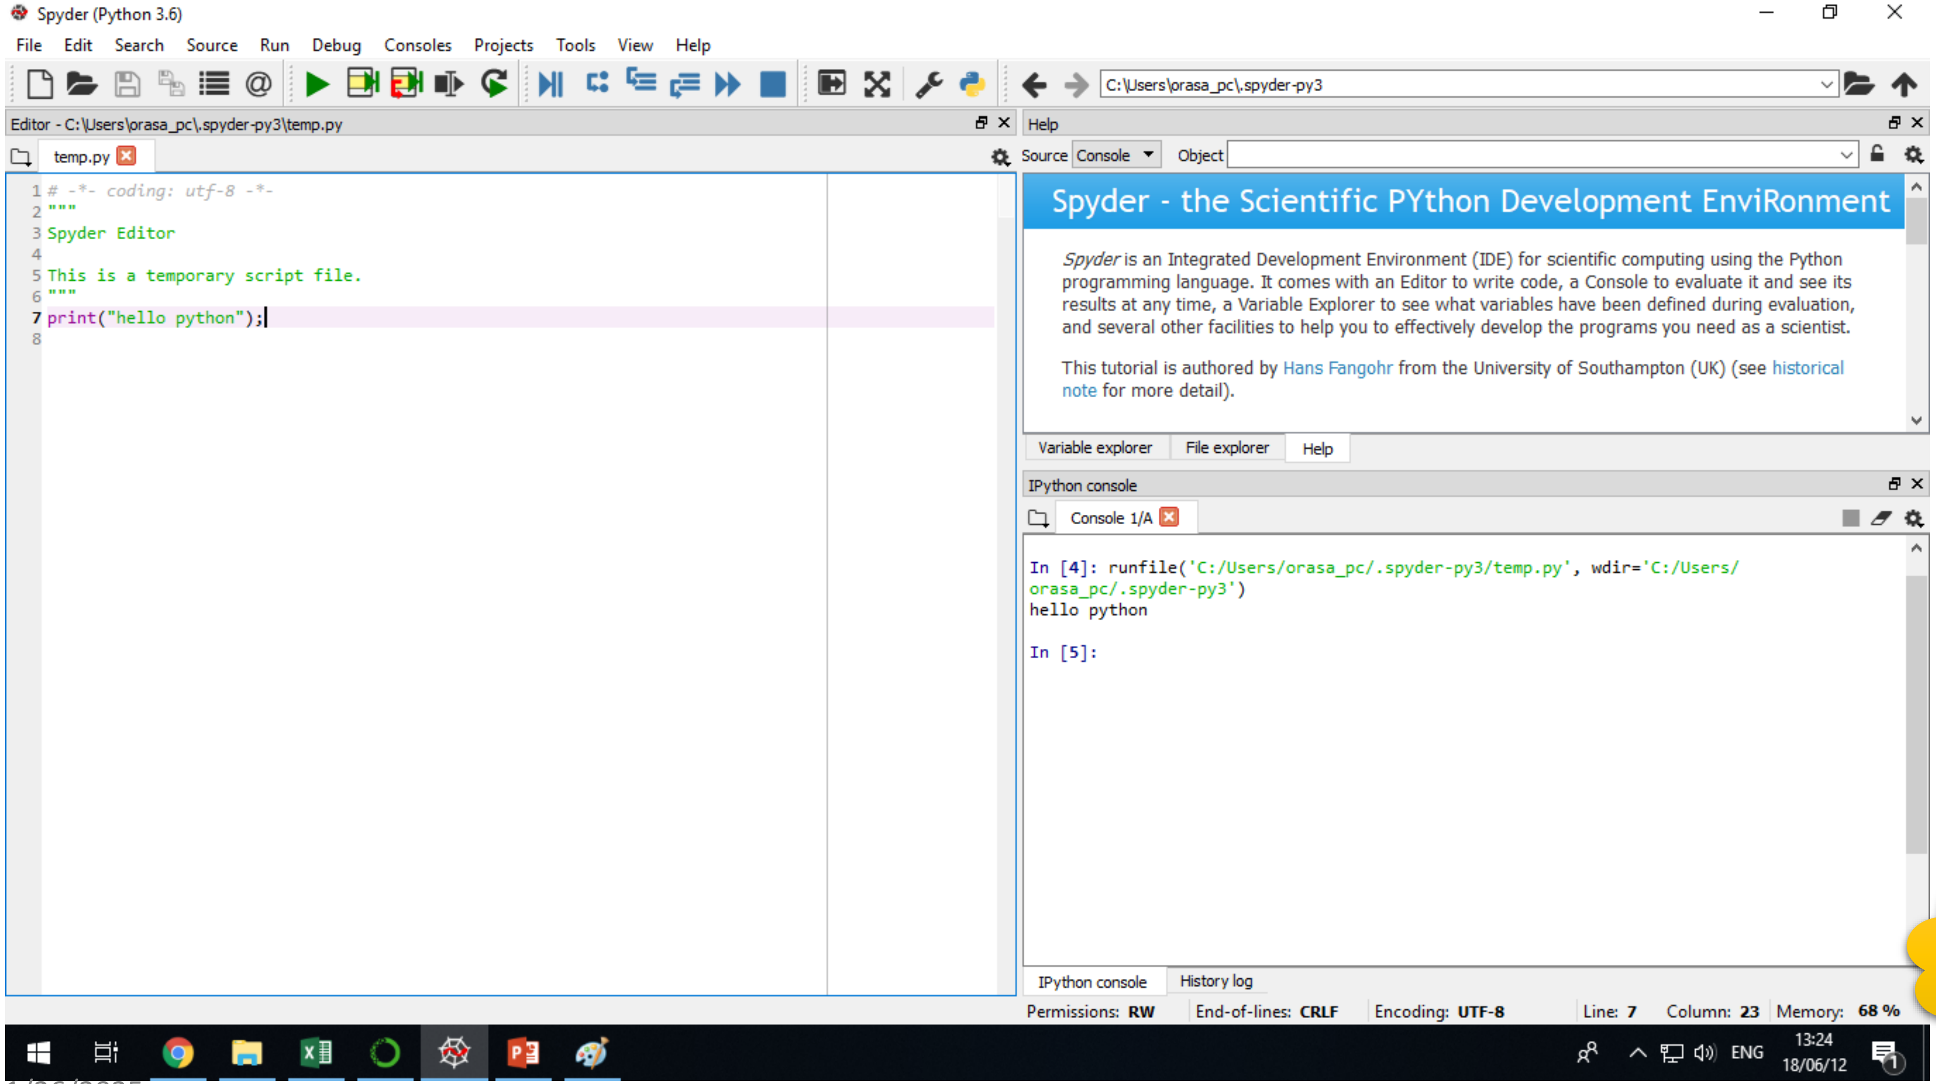

CS

[Jesús Rogel-Salazar. DATA, 2017]

spyder

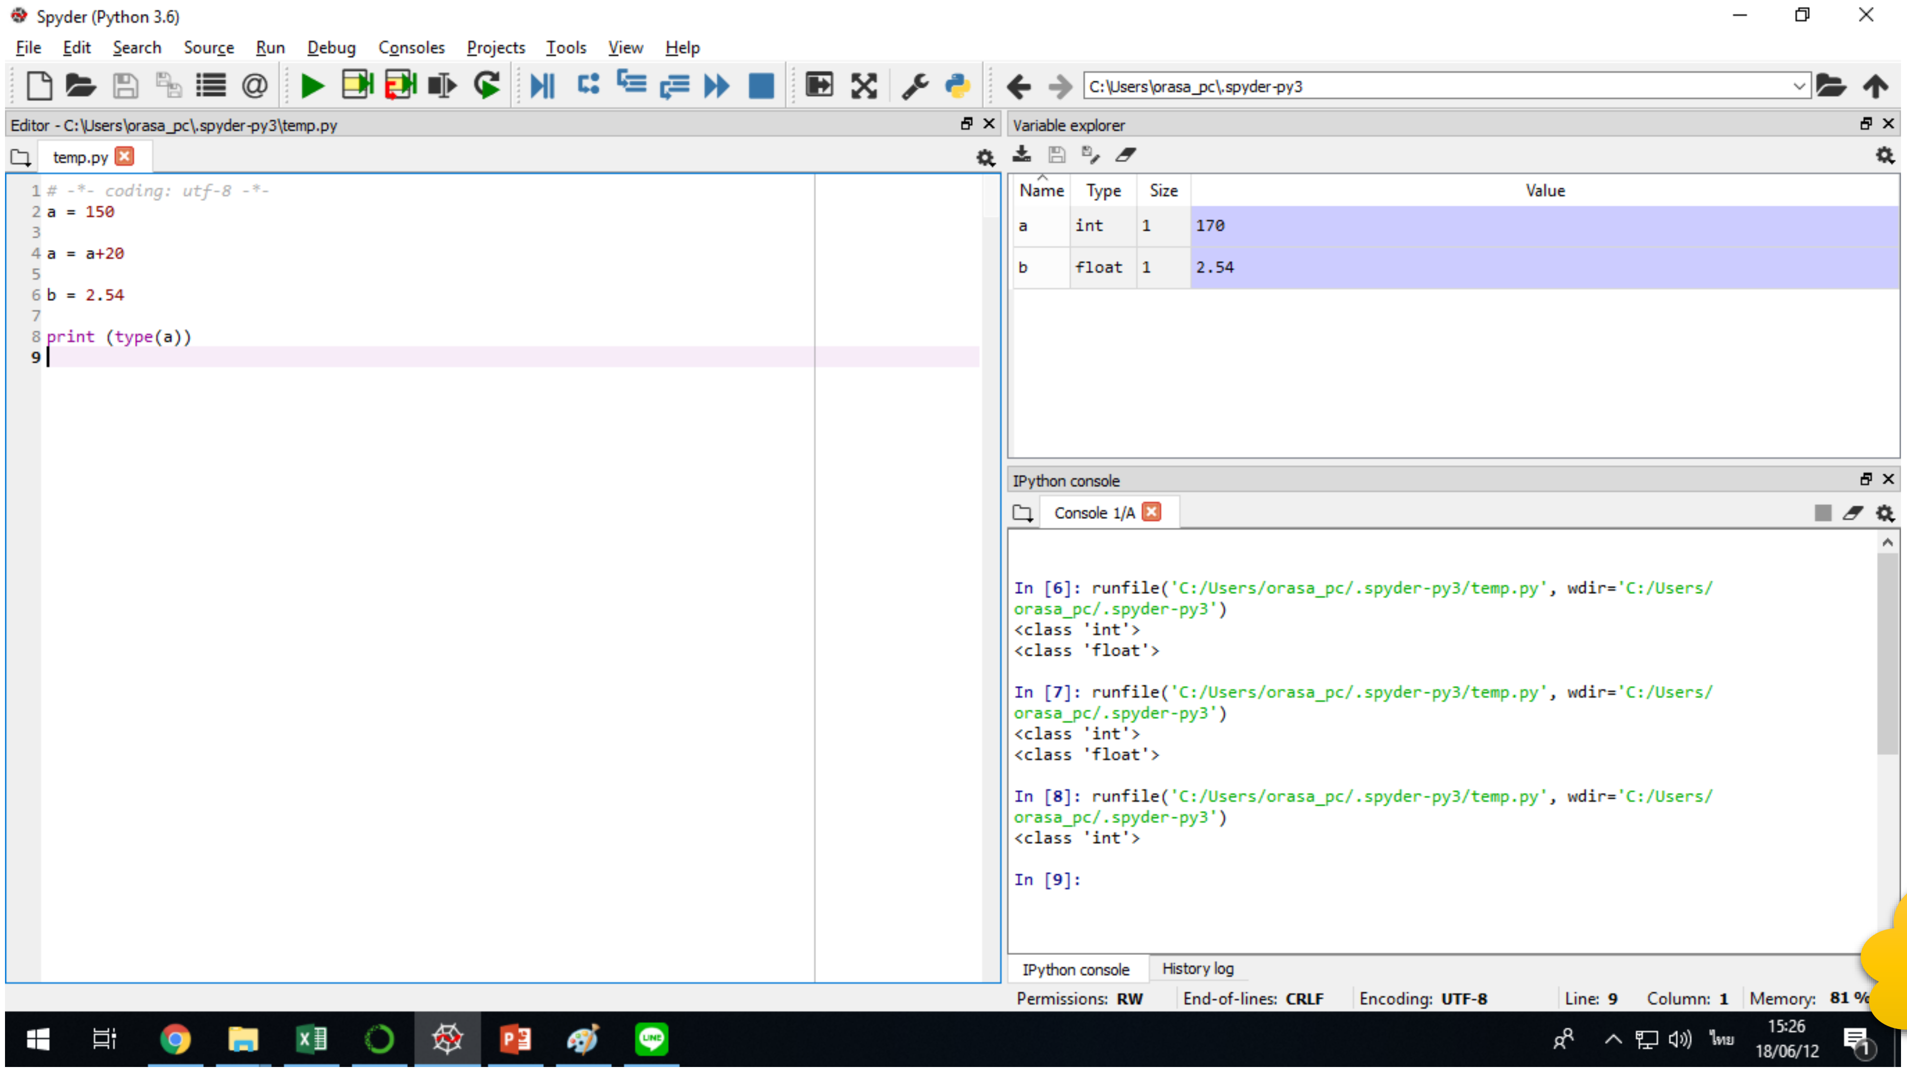

CS

[Jesús Rogel-Salazar. DATA, 2017]

spyder

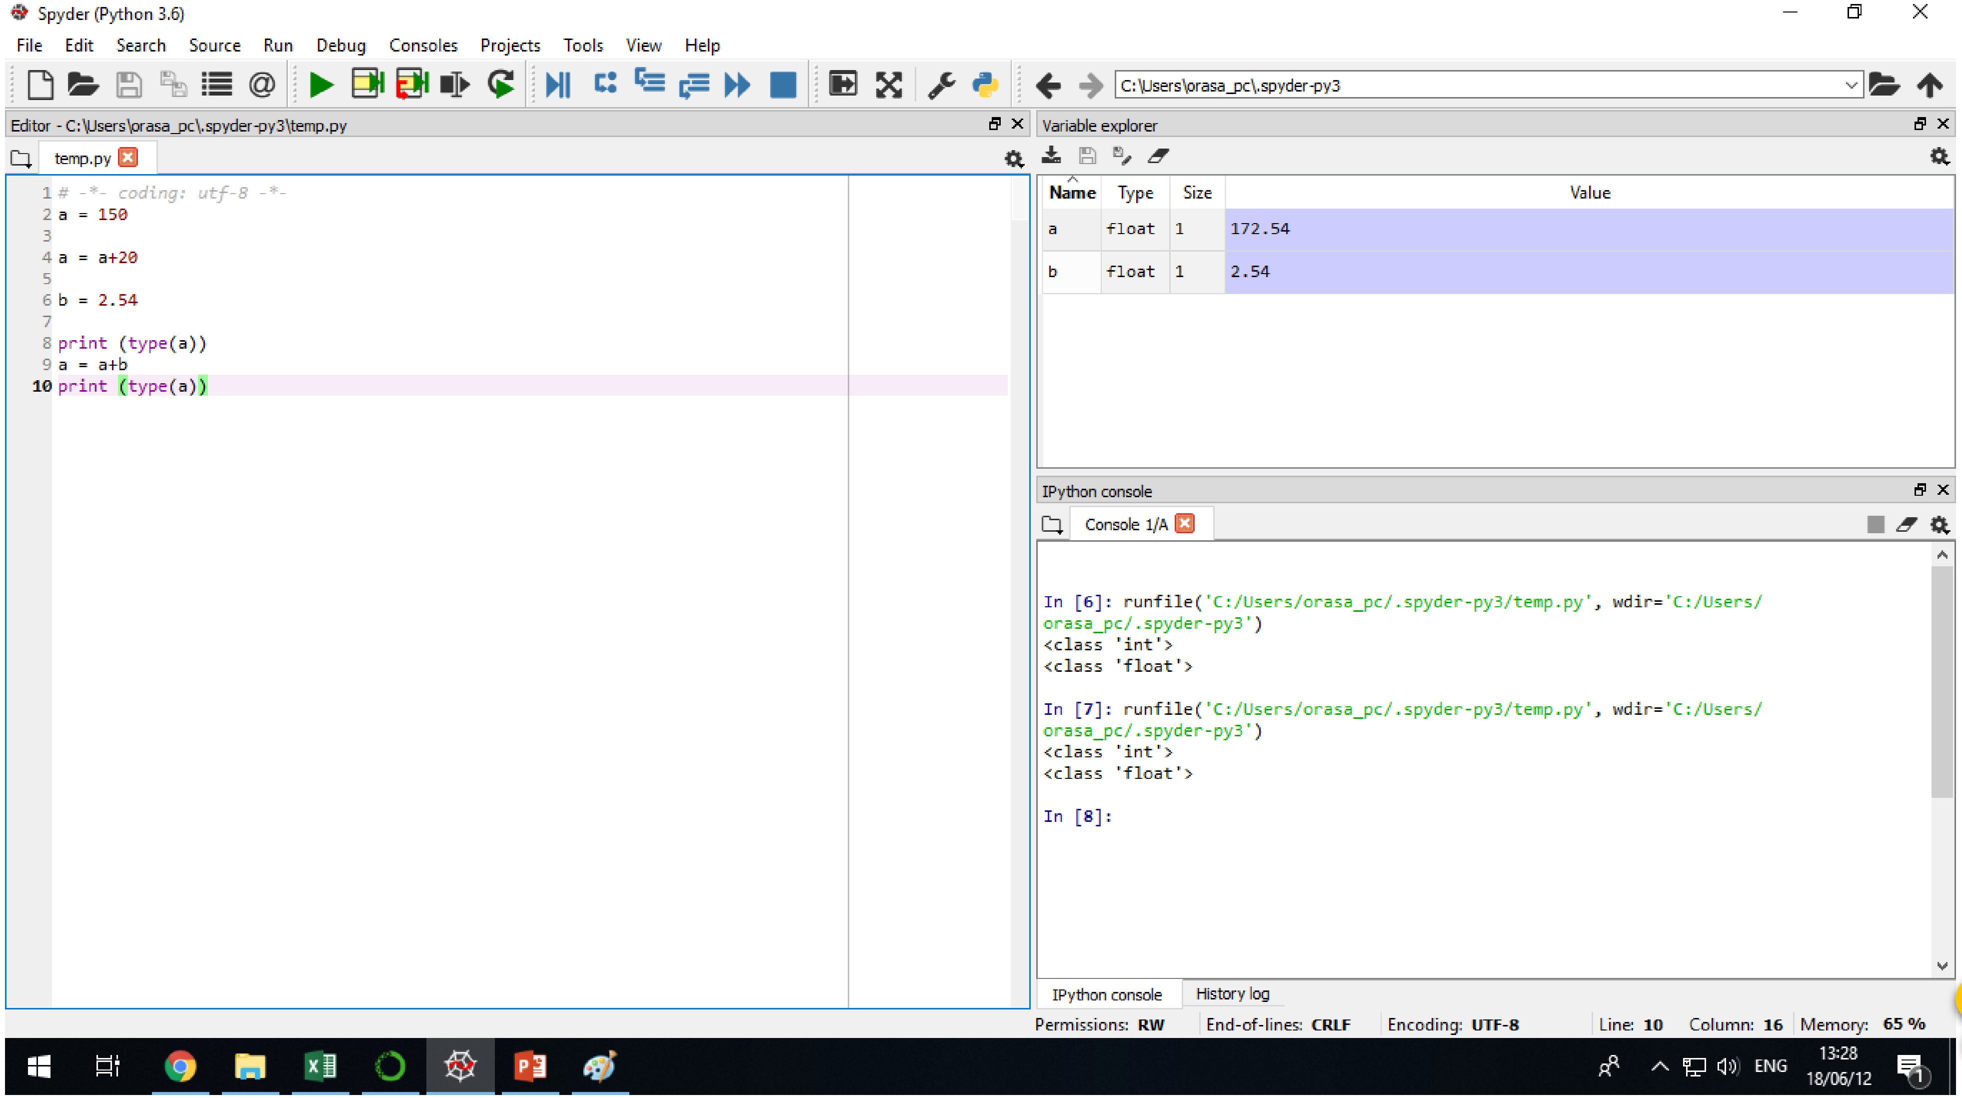

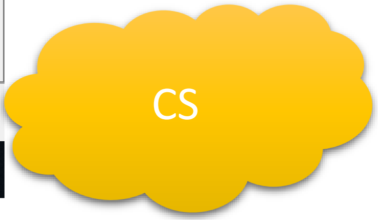

[Jesús Rogel-Salazar. DATA, 2017]

spyder

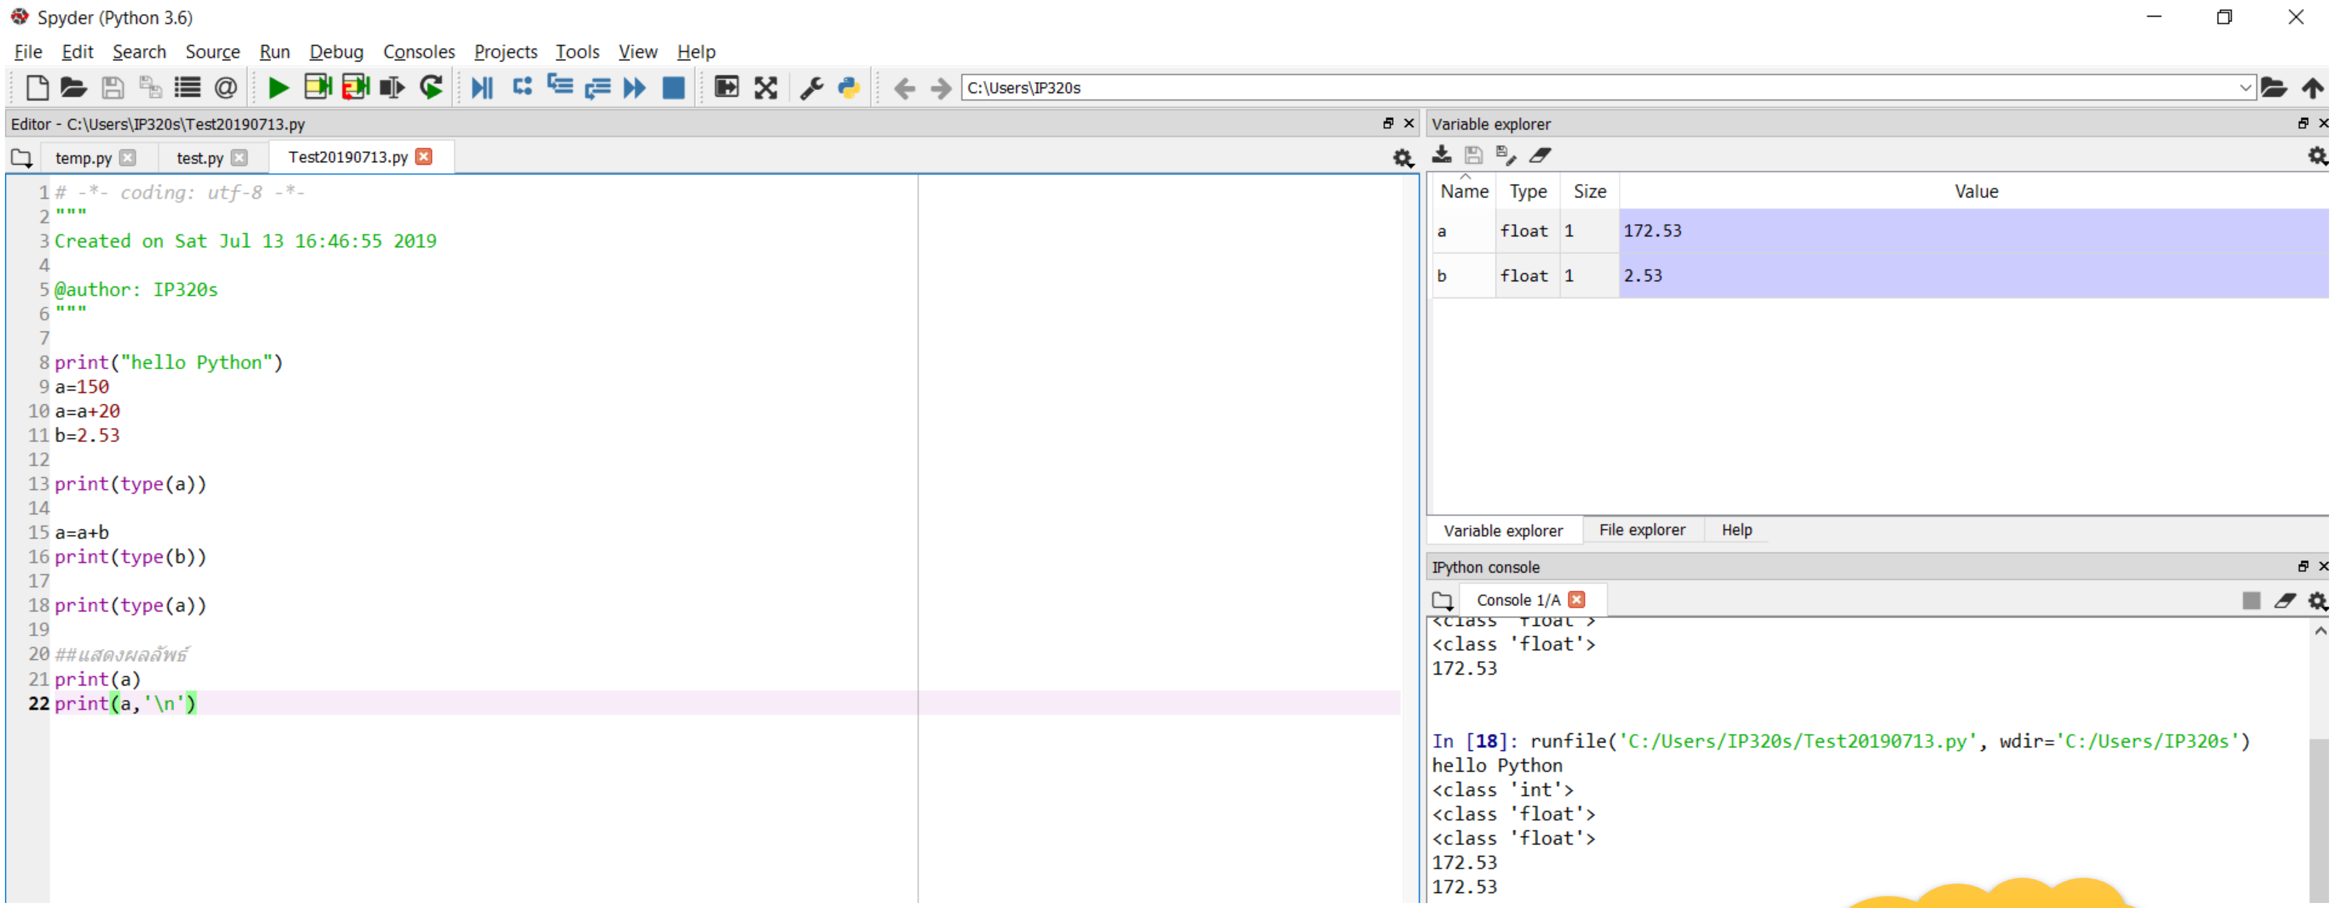

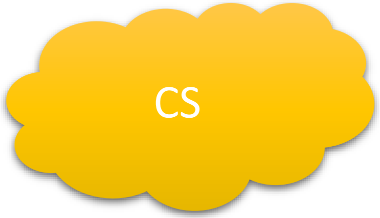

[Jesús Rogel-Salazar. DATA, 2017]

การแสดงข้อมูลรูปแบบต่าง ๆ

```
In [3]: z = 3 + 4j
        print(z)
```

```
In [5]: binary = "1011"
        a = int(binary, 2)
        print(a)
```

```
In [10]: octal_num = "15"
         b = int(octal_num, 8)
         print(b)
```

```
In [11]: hex_num = "1A"
         c = int(hex_num, 16)
         print(c)
```

CS

[Jesús Rogel-Salazar. DATA, 2017]

ชนิดของข้อมูล

ชื่อย่อ	ความหมาย	ตัวอย่าง
int	จำนวนเต็ม	12345
float	จำนวนจริง	123.45
complex	จำนวนเชิงซ้อน	123+45j
bool	บูล	True
str	สายอักขระ	'12345'
list	ลิสต์	[1,2,3,4,5]
tuple	ทูเพิล	(1,2,3,4,5)
set	เซ็ต	{1,2,3,4,5}
dict	ดิกชันนารี	{'ก':1,'ข':2,'ค':3,'ง':4,'จ':5}
range	เรนจ์	range(1,6)

CS

pandas

In [1]:

```
import pandas as pd
data = {
        'dateofbirth':['22/11/2025','23/11/2025', '24/11/2025'],
    'name':['ann', 'boy', 'bee'],
    'age':[20,24,30],
}
print(data)
```

In [2]:

```
df =pd.DataFrame(data)
```

In [3]:

```
df
```

CS

[Jesús Rogel-Salazar. DATA, 2017]

Numpy

```python
import numpy as np
a = np.array([1,2,3,4,5])
print(a)
```

CS

[Jesús Rogel-Salazar. DATA, 2017]

Matplotlib

```python
import matplotlib.pyplot as plt
x=2,3,4,5
y=1,2,3,4
plt.plot(x,y)
plt.show()
```

CS

[Jesús Rogel-Salazar. DATA, 2017]

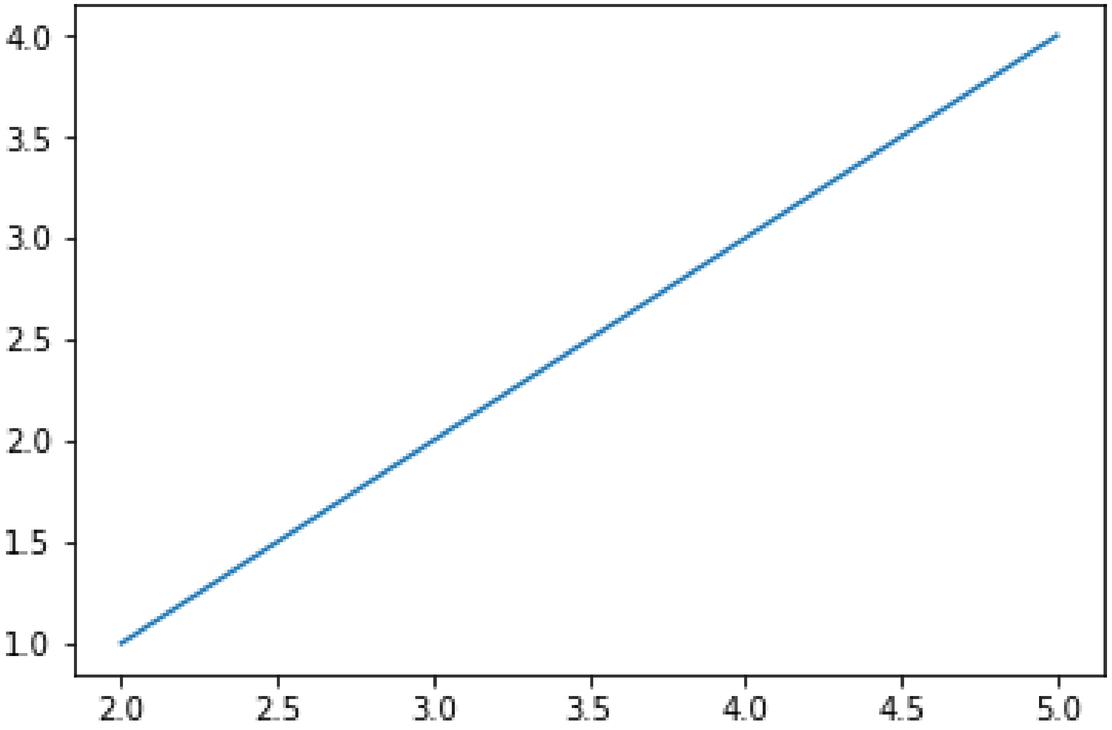

CS

[Jesús Rogel-Salazar. DATA, 2017]

อ้างอิง

- http://www.zhanjunlang.com/resources/tutorial/Data%20Science%20from%20Scratch%20First%20Principles%20with%20Python.pdf
- Jesús Rogel-Salazar.DATA SCIENCE AND ANALYTICS WITH PYTHON. CRC Press Taylor & Francis Group, 2017.

CS