



รายงาน

การสืบค้นงานวิจัยการตรวจจับบทความข่าวปลอมแบบเรียลไทม์โดยใช้การเรียนรู้เชิงลึก

นายกฤษติชัย รัตนวัน

นายกิตติศักดิ์ วันหวัง

นายชิตณุพงศ์ นาควงศ์

นายธนดล สนวนงาม

นายบุรพา ประกอบผล

นายสิทธิกร พุ่มโพธิ์

โครงงานนี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตรวิทยาศาสตรบัณฑิต

สาขาวิชาวิทยาการคอมพิวเตอร์ ภาควิชาวิทยาศาสตร์ข้อมูลเบื้องต้น

คณะวิทยาศาสตร์และเทคโนโลยี มหาวิทยาลัยเทคโนโลยีราชมงคลกรุงเทพ

ปีการศึกษา 2568

สารบัญ

เนื้อหา	หน้า
สารบัญ	๗
บทที่ 1 ที่มาและความสำคัญของปัญหา	1
บทที่ 2 วิธีการดำเนินการ	2
บทที่ 3 เทคนิค Machine Learning ที่ใช้ในงานวิจัย	4
บทที่ 4 ผลลัพธ์	6
บรรณานุกรม	10

บทที่ 1

ที่มาและความสำคัญของปัญหา

ในปัจจุบัน แม้ว่าประชากรรุ่นใหม่จะมีคุณลักษณะที่โดดเด่นในด้านการเพิ่มขึ้นของการใช้งานเทคโนโลยีสารสนเทศ แต่อุปสรรคที่ใหญ่ที่สุดประการหนึ่งคือปัญหาเรื่องข่าวปลอมที่แพร่กระจายบนอินเทอร์เน็ตได้รวดเร็วกว่าข่าวจริงอย่างมาก ข้อมูลที่บิดเบือนเหล่านี้สามารถส่งผลกระทบในวงกว้าง ทั้งการหลอหลอมความเห็นของสาธารณชน การเปลี่ยนแปลงผลการเลือกตั้ง หรือแม้แต่การกระตุ้นให้เกิดความไม่สงบในสังคม การที่บทความข่าวเท็จหรือข่าวปลอมปรากฏขึ้นบ่อยครั้งนั้นเป็นอันตรายต่อชื่อเสียงของสำนักข่าวต่าง ๆ และบั่นทอนความเชื่อมั่นของชุมชนที่มีต่อช่องทางข้อมูลข่าวสาร อย่างไรก็ตาม การค้นหาแนวทางที่ดีที่สุดในการตรวจจับข่าวปลอมแบบเรียลไทม์ยังคงเป็นความท้าทายที่สำคัญในปัจจุบัน

สาเหตุที่ทำให้การระบุข่าวปลอมทำได้ยากนั้นประกอบด้วยปัจจัยหลายประการ เช่น ลักษณะของปัญหาที่มีความซ้อนกัน ปริมาณของบทความจำนวนมากมหาศาลที่ถูกผลิตขึ้นในทุก ๆ วินาที และข้อเท็จจริงที่ว่าบทความปลอมเหล่านี้มักจะเลียนแบบลักษณะของบทความข่าวจริงได้อย่างแนบเนียน สำหรับเทคนิคการตรวจสอบข้อเท็จจริงที่มีอยู่ในปัจจุบันมักจะมีขั้นตอนที่ล่าช้า ต้องใช้แรงงานคนจำนวนมาก และไม่เหมาะสมต่อการจัดการกับปริมาณข้อมูลที่มีอยู่มหาศาลบนโลกอินเทอร์เน็ต ด้วยเหตุนี้ การใช้วิธีการทำงานแบบอัตโนมัติและระบบอัจฉริยะจึงเป็นหัวใจสำคัญในการแก้ปัญหา


เพื่อเอาชนะข้อจำกัดดังกล่าว งานวิจัยชิ้นนี้จึงมุ่งเป้าไปที่การระบุบทความข่าวปลอมแบบเรียลไทม์ ผ่านการใช้อัลกอริทึมที่ซับซ้อนในการเรียนรู้ของเครื่อง (Machine Learning) และการเรียนรู้เชิงลึก (Deep Learning) โดยเราได้เลือกใช้ชุดโมเดลที่หลากหลายซึ่งแต่ละโมเดลถูกออกแบบมาเพื่อแก้ปัญหาที่แตกต่างกันในสาขาการประมวลผลภาษาธรรมชาติและการจำแนกข้อมูล ได้แก่ โครงข่ายประสาทแบบ Long Short-Term Memory (LSTM) โมเดล ALBERT (A Lite BERT) และโมเดล FNNet ที่ออกแบบมาเพื่อตรวจจับข่าวปลอม โดยเฉพาะ สุดท้ายคือโมเดลผสมระหว่าง Convolutional Neural Network (CNN) และ Recurrent Neural Network (RNN) ซึ่งมีความสามารถในการดึงคุณลักษณะสำคัญทั้งเชิงพื้นที่และเชิงเวลา นำไปสู่การจำแนกข้อมูลที่มีความน่าเชื่อถือสูง ด้วยการนำเทคนิคเหล่านี้มาใช้ เราเชื่อมั่นว่าจะสามารถสร้างโซลูชันที่คัดกรองข่าวจริงออกจากข่าวปลอมได้อย่างมีความแม่นยำสูง เพื่อเป็นส่วนหนึ่งในการต่อสู้กับปัญหาข่าวปลอมอย่างต่อเนื่อง

บทที่ 2


วิธีการดำเนินการ

ระเบียบวิธีวิจัยที่นำเสนอในการศึกษานี้ประกอบด้วยสองระยะหลัก โดยระยะการฝึกสอน (Training phase) เป็นขั้นตอนแรกดังที่แสดงในรูปที่ 1 ซึ่งจะเป็นการดึงข้อมูลสำหรับฝึกสอนออกมาจากฐานข้อมูล จากนั้นข้อมูลที่ถูกดึงออกมานี้จะถูกนำไปใช้ในกระบวนการทำความสะอาดข้อมูลที่มีความไม่สอดคล้องกัน (เนื่องจากการขาดข้อมูลนำเข้าในรูปแบบดิบ) ซึ่งรวบรวมมาจากแหล่งข้อมูลที่หลากหลาย

หลังจากนั้น ข้อมูลจะเข้าสู่กระบวนการเตรียมข้อมูลเบื้องต้น (Preprocessed) และถูกแปลงให้อยู่ในรูปแบบของเวกเตอร์คำ (Word vectors) ตามหลักการฝังคำ (Word embeddings) จากนั้นจึงทำการปรับจูน (Fine-tuning) โมเดลการเรียนรู้เชิงลึกโดยใช้การฝังคำที่ผ่านการฝึกสอนมาแล้วล่วงหน้า (Pretrained word embeddings) โดยเราได้ประเมินอัลกอริทึมหลักต่าง ๆ ซึ่งรวมถึง ALBERT, CNN+RNN, Bidirectional LSTM และ FNNet หลังจากนั้นจะทำการบันทึกโมเดลที่ผ่านการฝึกสอนแล้วลงในฐานข้อมูล เพื่อให้สามารถนำไปใช้ในระยะการทดสอบ (Testing phase) ต่อไปตามที่แสดงในรูปที่ 2



รูปที่ 1 ระยะการฝึกสอน



รูปที่ 2 ระยะการทดสอบ

บทที่ 3

เทคนิค Machine Learning ที่ใช้ในงานวิจัย

บทความวิจัยนี้มุ่งเน้นไปที่การเปรียบเทียบตัวจำแนกประเภท (Classifiers) หลายตัวสำหรับการตรวจจับข่าวปลอม โดยใช้ชุดข้อมูล ISOT Fake News, Fake or Real News และชุดข้อมูลข่าวสุดท้าย โดยมีรายละเอียดของแต่ละโมเดลดังนี้


LSTM (Long Short-Term Memory): ให้ประสิทธิภาพการทำงานในระดับสูง เนื่องจากเน้นไปที่การเรียนรู้ความสัมพันธ์เชิงเวลา (Temporal dependencies) ในข้อความและการจับกระแสของบริบท ซึ่งส่งผลกระทบต่อตรวจจับข่าวปลอม โมเดลนี้สามารถตรวจพบความไม่สอดคล้องในรูปแบบการเขียนหรือการให้ข้อมูล ตัวอย่างเช่น กรณีที่หัวข้อข่าวมีความแตกต่างจากเนื้อหาภายในบทความ

ALBERT (A Lite BERT): เป็นโมเดลที่นำเสนอโดยใช้เทคนิคการแยกเมทริกซ์การฝังคำ (Factorized embedding matrix) และการใช้พารามิเตอร์ร่วมกันระหว่างชั้น (Cross-layer parameter sharing) ซึ่งสามารถทำผลลัพธ์ได้ถึง 100% ทั้งในด้านความแม่นยำ (Accuracy), ความแม่นยำในการพยากรณ์ (Precision), การระลึก (Recall) และค่า F1-score โดย ALBERT แสดงให้เห็นถึงประสิทธิภาพที่โดดเด่นเนื่องจากผลลัพธ์ถูกปรับให้เหมาะสมกับชุดข้อมูลตรวจจับข่าวปลอม ซึ่งช่วยในการเรียนรู้ข่าวปลอมจากลักษณะทางภาษาที่ผิดปกติ ทั้งในแง่ของการเรียงลำดับประโยคและการวิเคราะห์บริบท

CNN+RNN (Combined Model): เมื่อใช้งานโมเดลผสมที่ดึงคุณลักษณะเฉพาะที่ (Local features) ด้วย CNN และประมวลผลข้อมูลลำดับด้วย RNN พบว่าผลลัพธ์ที่ได้นั้นดีและมีความเสถียร โดยมีประโยชน์อย่างยิ่งในการระบุการสะกดผิดที่พบบ่อยและการใช้คำสแลง ซึ่งผู้สร้างข่าวปลอมมักนิยมนำมาใช้เพื่อเพิ่มปริมาณเนื้อหาข่าวปลอม

FNNNet (Feed-forward Neural Network): ถูกนำมาใช้เป็นตัวจำแนกสุดท้ายที่รับคุณลักษณะมาจากโมเดลอื่น ๆ รวมถึง BERT และ LSTM เมื่อมีการนำการฝังคำเชิงบริบท (Contextual embeddings), รูปแบบลำดับ และข้อมูลระดับหน่วยคำย่อย (Sub-word information) มาพิจารณาร่วมกัน FNNNet จะช่วยเพิ่มความสามารถในการตัดสินใจแยกแยะระหว่างหมวดหมู่ข่าวจริงและข่าวปลอมได้อย่างแม่นยำ

ในงานนี้เราขอเสนอสถาปัตยกรรมกลุ่มการเรียนรู้เชิงลึกที่ประกอบด้วยชั้นข้อมูลที่เชื่อมต่อกันเพื่อชิงโครโนซ์ข้อมูลนำเข้า ดังที่แสดงในแบบจำลองในรูปที่ 3 โดยเราเริ่มต้นด้วย ชั้นนำเข้า (Input Layer) ที่มีรูปร่างข้อมูลขนาด (16, 64) หลังจากนั้นข้อมูลจะผ่านชั้น AlbertEmbeddings เพื่อให้ได้ตัวแทนข้อมูลแบบฝังตัวขนาด (16, 128) ต่อจากนั้นชั้น Albert Transformer จะประมวลผลข้อมูลต่อจนได้ผลลัพธ์เป็นบทสรุปที่มีความครอบคลุมขนาด (16, 768) และเพื่อเพิ่มความสามารถในการปรับใช้กับข้อมูลทั่วไป (Generalize) รวมถึงแก้ไขปัญหาการเรียนรู้จดจำข้อมูลมากเกินไป (Over-fitting) จึงได้มีการใช้ชั้น Dropout มาช่วยประมวลผล ซึ่งถูกนำมาใช้โดยยังคงรักษารูปร่างขนาดของข้อมูลขาออก (Dimension) ไว้ที่ (16, 768) และสุดท้าย ขนาดข้อมูลที่ (16, 2) จะเป็นตัวกำหนดเป้าหมายสองประการสำหรับการจำแนกประเภท (ซึ่งก็คือ ข้าวจริง และ ข้าวปลอม) สถาปัตยกรรมนี้ทำให้สามารถดึงคุณลักษณะ (Features) และจำแนกประเภทข้อมูลได้อย่างมีประสิทธิภาพ ซึ่งถือเป็นกิจกรรมหลักที่เกี่ยวข้องในการศึกษาวิจัยครั้งนี้




รูปที่ 3 แบบจำลองสถาปัตยกรรมกลุ่มการเรียนรู้เชิงลึก

บทที่ 4

ผลลัพธ์


Algorithms	Dataset Used	F1-Score	Precision	Recall	Accuracy
Results from Proposed Work					
ALBERT	ISOT	1.00	1.00	1.00	100%
	Fake News	1.00	1.00	1.00	100%
	Real or Fake	1.00	1.00	1.00	100%
	Fake News	1.00	1.00	1.00	100%
	Detection				
LSTM	ISOT	0.99	0.99	0.99	100%
	Fake News	0.97	0.97	0.97	100%
	Real or Fake	0.77	0.77	0.77	100%
	Fake News	0.85	0.85	0.85	84.79%
CNN + RNN	ISOT	1.00	1.00	1.00	99%
	Fake News	0.98	0.98	0.98	99%
	Real or Fake	1.00	1.00	1.00	100%
	Fake News	1.00	1.00	1.00	100%
FNNet	ISOT	0.99	0.99	0.99	100%
	Fake News	0.99	0.99	0.99	100%
	Real or Fake	0.79	0.79	0.79	79%
	Fake News	0.93	0.93	0.93	93%

ตารางที่ 1 ตารางเปรียบเทียบมาตรวัดประสิทธิภาพของโมเดล




รูปที่ 4 แสดงแผนภูมิแท่งที่แสดงถึงสัดส่วนของรูปแบบข้อมูลของแต่ละโมเดลเรียนรู้ได้อย่างถูกต้อง

ในตารางที่ 1 แสดงการเปรียบเทียบมาตรวัดประสิทธิภาพของโมเดล ALBERT, LSTM, CNN+RNN และ FNet จากชุดข้อมูลทั้ง 4 ชุดที่ได้กล่าวไป ซึ่งผลลัพธ์เน้นย้ำให้เห็นว่าโมเดล ALBERT มีความแม่นยำคงที่อยู่ที่ 100% ในทุกภารกิจ



รูปที่ 5 เน้นย้ำประสิทธิภาพของโมเดล ALBERT ในการตรวจจับขบวนการ โดยแสดง Confusion Matrices (เมทริกซ์ความสับสน)



รูปที่ 6 แสดง Confusion Matrices ของชุดข้อมูลชุดเดียวกันแต่เป็นการใช้โมเดล CNN+RNN ซึ่งถือเป็นโมเดลที่มีประสิทธิภาพดีเป็นอันดับที่สอง

Sample of true news	Model	Prediction
The state government is nearing the final stages of selecting a site for Bengaluru's second international airport, with the location likely to be near Nelamangala. After a thorough evaluation, the area between Nelamangala and Kunigal, along National Highway 75, has been identified as the most suitable for the new airport, according to sources.	LSTM	Fake
	ALBERT	True
	CNN + RNN	True
	FNNet	True

ตารางที่ 2 ผลการคาดการณ์ข่าวปลอมของแต่ละโมเดล

ในตารางที่ 2 พบว่าในขณะที่โมเดล ALBERT, CNN+RNN และ FNNet สามารถระบุข่าวได้อย่างถูกต้องว่าเป็นข่าวจริง แต่โมเดล LSTM กลับมีความผิดพลาด โดยจำแนกข่าวนั้นว่าเป็นข่าวปลอม

Sample of fake news	Model	Prediction
Fred Rogers served as a sniper during the Vietnam War and had a large number of confirmed kills. Fred Rogers wore his iconic sweaters to conceal the extensive tattoos on his arms that were acquired while serving in the military.	LSTM	Fake
	ALBERT	Fake
	CNN + RNN	Fake
	FNNet	Fake

ตารางที่ 3 ตัวอย่างการระบุข่าวปลอม

สำหรับตารางที่ 3 โมเดลทั้งหมดซึ่งได้แก่ LSTM, ALBERT, CNN+RNN และ FNNet สามารถระบุข่าวได้อย่างถูกต้องว่าเป็นข่าวปลอม ซึ่งแสดงให้เห็นถึงความแม่นยำของทุกโมเดลในตัวอย่างนี้

บรรณานุกรม

Ahmed, N., Shahbaz, M., Khalil, H. S. U. R., & Maroof, Z. (2024). Real-Time Detection of Fake News Articles Using Deep Learning Techniques. *2024 2nd International Conference on Sustainable Computing and Smart Systems (ICSCSS)*, 688-693.
<https://doi.org/10.1109/ICSCSS60660.2024.11019208>